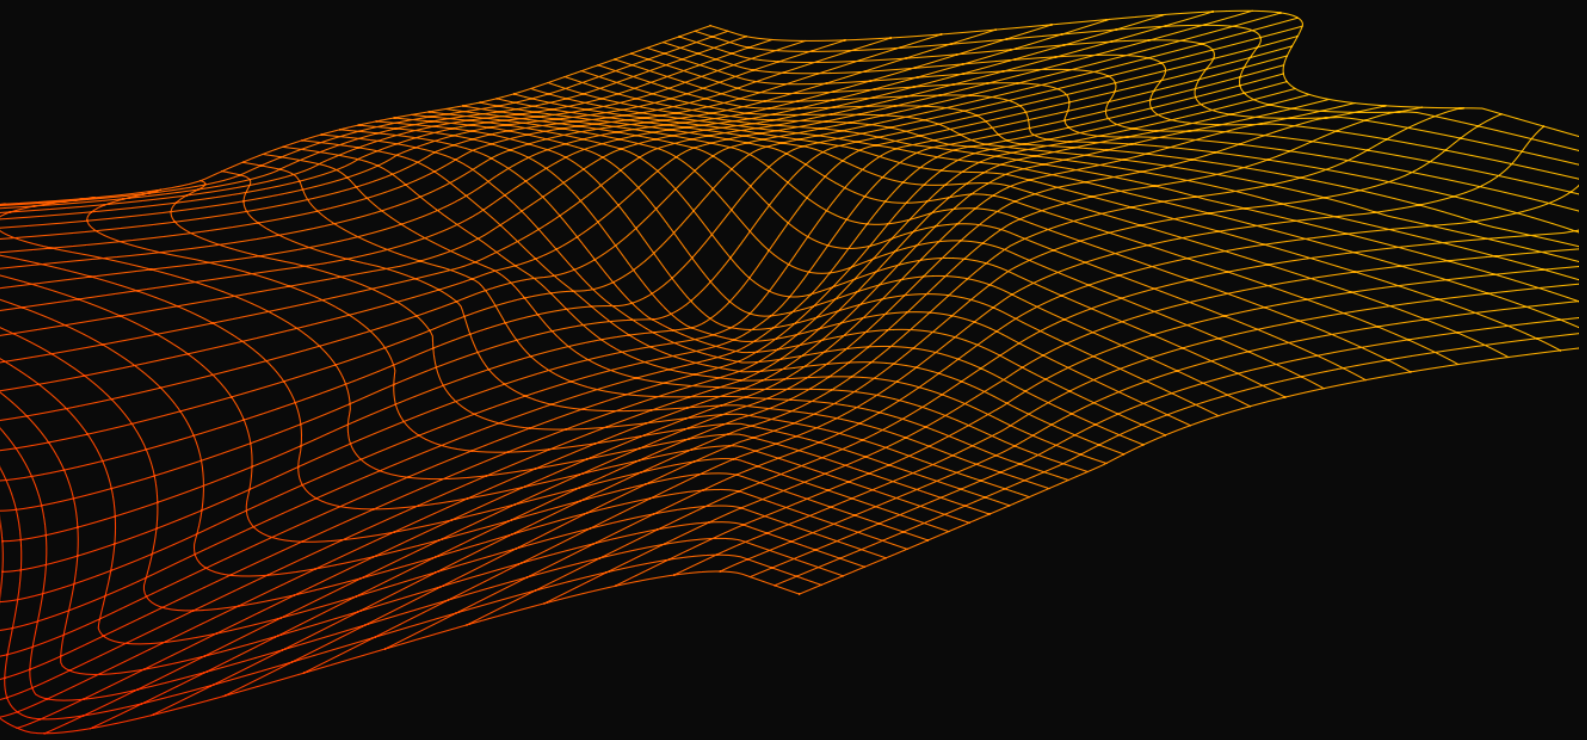
TAREA UNIDAD 1

Conociendo los Sistemas de Inteligencia Artificial

Modelos de Inteligencia Artificial (MIA)



Inteligencia Artificial y Big Data

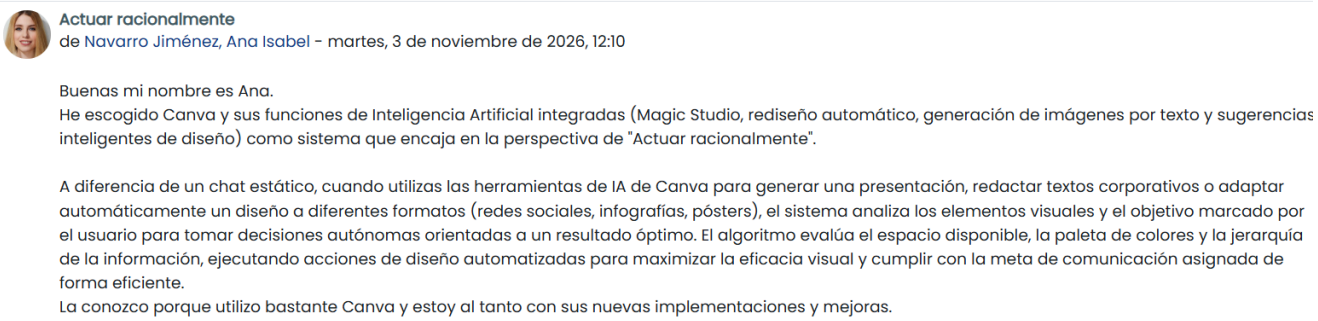
Ana Isabel Navarro Jiménez

ÍNDICE

1. Perspectivas de la IA (Enfoques Clásicos, IA Agéntica y Modelos de Razonamiento)..... 3
1.1. Introducción y alcance del sistema..... 3
1.2. Nombre, características y cómo funciona..... 3
1.3. ¿Donde se aplica y que ofrece?..... 4
1.4. Clasificación conceptual..... 4
1.5. Arquitectura técnica de extremo a extremo..... 4
1.6. Interacción hombre-máquina..... 5
2. Campos de aplicación de la Inteligencia Artificial, SLMs y Arquitecturas de Negocio (RAG vs. Fine-Tuning)..6
2.1. Análisis de Casos Reales de Eficiencia Operativa..... 6
2.2. Nuevas Formas de Interacción: Multimodalidad y Copilotos..... 6
2.3. Impacto Social, Beneficios y Dilemas Éticos..... 7
2.4. Propuesta Futura Innovadora y Retorno de Inversión (ROI)..... 8
3. Exploración de Técnicas, Guardrails, XAI y Sostenibilidad (Green AI)..... 8
3.1. Fundamentación técnica..... 8
3.2. Caso práctico y simulación..... 9
3.3. Capas de contención (Guardrails)..... 10
3.4. Explicabilidad (XAI) vs. Caja Negra..... 10
3.5. Sostenibilidad Ambiental (Green AI)..... 11
4. Gobierno Normativo, AI Act (UE 2024/1689), Marcas de Agua (C2PA) y Shadow AI..... 11
4.1. Clasificación de Riesgo según la Ley de IA de la UE (AI Act)..... 11
4.2. Protección de Datos (RGPD) y Ciberseguridad..... 12
4.3. Auditoría y Mitigación de Sesgos Algorítmicos..... 12
4.4 Transparencia, Etiquetado y Control de Shadow AI..... 12
5. Paradoja de la Productividad, Gobierno del Workslop y Matriz Human-in-the-loop..... 13
5.1. Evitando la Burocracia Automatizada y Métrica de Impacto Real..... 13
5.2. Delimitación de Autonomía y Supervisión Humana (Matriz Human-in-the-Loop)..... 13
5.3. Decálogo de Uso Responsable de la IA..... 14

1. Perspectivas de la IA (Enfoques Clásicos, IA Agéntica y Modelos de Razonamiento)

Parte 1: Participación en el foro:



Actuar racionalmente
de Navarro Jiménez, Ana Isabel - martes, 3 de noviembre de 2026, 12:10

Buenas mi nombre es Ana.
He escogido Canva y sus funciones de Inteligencia Artificial integradas (Magic Studio, rediseño automático, generación de imágenes por texto y sugerencias inteligentes de diseño) como sistema que encaja en la perspectiva de "Actuar racionalmente".

A diferencia de un chat estático, cuando utilizas las herramientas de IA de Canva para generar una presentación, redactar textos corporativos o adaptar automáticamente un diseño a diferentes formatos (redes sociales, infografías, pósters), el sistema analiza los elementos visuales y el objetivo marcado por el usuario para tomar decisiones autónomas orientadas a un resultado óptimo. El algoritmo evalúa el espacio disponible, la paleta de colores y la jerarquía de la información, ejecutando acciones de diseño automatizadas para maximizar la eficacia visual y cumplir con la meta de comunicación asignada de forma eficiente.
La conozco porque utilizo bastante Canva y estoy al tanto con sus nuevas implementaciones y mejoras.

Parte 2:

INFORME TÉCNICO: PROPUESTA DE INTELIGENCIA ARTIFICIAL EN EL ENTORNO SANITARIO: **DERMASYS**

1.1. Introducción y alcance del sistema

El diseño se trata de un sistema avanzado de Inteligencia Artificial enfocado en el sector sociosanitario y dermatológico pediátrico. El sistema aborda una necesidad crítica en la gestión asistencial como lo es la monitorización temprana y el seguimiento clínico de la dermatitis atópica infantil.

El sistema aborda una necesidad crítica en la gestión asistencial y el flujo de trabajo clínico el seguimiento de la dermatitis atópica infantil, la cual se encuentra sistemáticamente infradiagnosticada. Actualmente, los pediatras de atención primaria no disponen de tiempo ni de herramientas para releer cada historial clínico y detectar de forma sistemática los patrones clave que indican esta gravedad (brotes recurrentes, escalado de corticoides tópicos, comorbilidades atópicas asociadas como asma o rinitis alérgica, y alteraciones del sueño). El sistema optimiza este proceso analizando historiales clínicos electrónicos para levantar alertas tempranas y guiar una derivación eficiente al especialista.

1.2. Nombre, características y cómo funciona

Nombre del sistema: **Dermasys**

Dermasys es una plataforma tecnológica inteligente de triaje, análisis preliminar y gestión coordinada enfocada en la dermatitis atópica infantil. Funciona mediante un flujo de extremo a extremo que recopila datos del historial clínico electrónico (texto libre o prescripciones), aplica modelos de procesamiento de lenguaje natural médico y reglas clínicas para calcular un puntaje de riesgo, y emite alertas por gravedad.

Dentro del ámbito normativo y de seguridad jurídica, **Dermasys no diagnostica** ni es un sistema de diagnóstico médico. El software no emite dictámenes clínicos ni pautas farmacológicas. Su propósito exclusivo es actuar como una herramienta de apoyo analítico y administrativo para estructurar la información y facilitar una derivación rápida, ordenada y segura hacia el pediatra o dermatólogo titular, informando explícitamente y de manera permanente al usuario desde el primer segundo de que interactúa con una IA de soporte y no con un médico.

1.3. ¿Donde se aplica y que ofrece?

Se despliega e integra en el entorno de la Atención Primaria y consultas de Pediatría, conectando de forma directa el ámbito doméstico con los centros de salud del sistema sanitario. Ofrece las siguientes prestaciones clave:

- Captura y estructuración de casos: Permite a los padres o familiares registrar de forma guiada la evolución de las lesiones cutáneas y los síntomas del menor.
- Análisis técnico preliminar y aviso de IA: Analiza la calidad visual de las fotografías y clasifica los datos estructurados, advirtiendo de forma permanente que se trata de una IA de apoyo.
- Derivación inteligente y acceso familiar: Canaliza de manera automatizada la información al panel del pediatra y habilita un portal seguro compartido para que los progenitores o tutores legales autorizados consulten citas y pautas prescritas por el especialista.

1.4. Clasificación conceptual

Perspectiva: Actuar racionalmente.

Dermasys se encuadra en la perspectiva de actuar racionalmente porque opera como un agente racional autónomo orientado a maximizar un objetivo específico y óptimo, analizar datos clínicos complejos y emitir alertas certeras para mejorar el proceso de derivación y la eficiencia asistencial con la información disponible. El sistema no busca imitar emociones humanas ni simular conciencia, percibe su entorno (historiales clínicos electrónicos y variables de salud estructuradas y no estructuradas), procesa la información mediante modelos lógicos y motores de scoring, y ejecuta la acción óptima (alertar al pediatra responsable y estructurar el expediente) para maximizar la salud y el bienestar del paciente pediátrico de la forma más eficiente posible.

1.5. Arquitectura técnica de extremo a extremo

Para garantizar la escalabilidad y la robustez técnica en entornos hospitalarios y de atención primaria, el flujo operativo de Dermasys se divide en cuatro fases modulares:

Fase 1: Recopilación y normalización (Ingesta de Datos): Ingesta los historiales clínicos electrónicos (texto libre de evoluciones, prescripciones y diagnósticos previos), aplicando procesos de anonimización para eliminar datos de identificación personal y normalizando la información bajo estándares interoperables.

Fase 2: Análisis IA: Un modelo de Machine Learning especializado procesa los datos normalizados combinando Procesamiento de Lenguaje Natural médico y reglas clínicas para evaluar brotes, escalado de tratamientos y comorbilidades atópicas, devolviendo un índice de probabilidad con explicabilidad asociada por paciente.

Fase 3: Alertas Accionables: Cuando el perfil de riesgo de un paciente supera el umbral preestablecido, el sistema emite una notificación automática al pediatra responsable, adjuntando un resumen con los hallazgos clínicos que justifican la alerta y sugiriendo la derivación temprana, siempre bajo el recordatorio explícito de soporte a la decisión.

Fase 4: Validación Clínica y Bucle de Aprendizaje Continuo: El especialista válida si la alerta fue un acierto o un falso positivo. Esta retroalimentación alimenta un dataset versionado que permite reentrenar periódicamente el algoritmo, mejorando la precisión.

1.6. Interacción hombre-máquina

Cuenta con una interfaz integrada con el historial clínico existente o mediante un portal web específico para el profesional sanitario. Ofrece un resumen estructurado y explicable de los hallazgos clínicos que justifican la alerta.

Tiene un grado de **autonomía media-alta** en las fases de recopilación, análisis masivo de datos e identificación predictiva de pacientes de alto riesgo. El sistema opera de manera autónoma en segundo plano procesando los historiales clínicos.

Supervisión (Human-in-the-loop), el sistema no diagnostica. Actúa estrictamente como un sistema de soporte a la decisión clínica que levanta la mano cuando un historial concentra señales compatibles con la enfermedad. La decisión de aceptar o rechazar la alerta, validar el caso y realizar la derivación final al especialista recae siempre y en todo momento sobre el pediatra o el especialista humano. Además, el feedback del médico (alerta aceptada/rechazada) cierra el bucle para reentrenar continuamente el modelo de forma segura.

Dentro de los riesgos, medidas éticas y seguridad de la interacción hombre-máquina podemos encontrar algunos como:

- **Riesgo de confianza excesiva o confusión de roles**: Que los padres, familiares o incluso el personal sanitario sobreestimen las capacidades del sistema y confundan una alerta de análisis con un diagnóstico médico firme.
    - Cómo remediarlo: Podemos incluir una interfaz con etiquetas y avisos permanentes de transparencia. En cada pantalla de la aplicación web y móvil se muestra de forma visible que Dermasys es una herramienta de soporte analítico asistida por IA y no un sistema de diagnóstico. Asimismo, la interacción obliga a que cualquier alerta de riesgo alto requiera la validación explícita del pediatra, impidiendo la autonomía clínica total del software

- **Riesgo de privacidad de datos sensibles de menores:** Exposición, filtrado o uso indebido de datos de salud altamente sensibles de pacientes pediátricos.
    - Medida de seguridad: El canal de comunicación entre los familiares y el centro de salud cuenta con cifrado de extremo a extremo y se aplican procesos estrictos de anonimización antes de que cualquier dato sea procesado por los modelos de lenguaje o procesamiento de texto. Estaría prohibido el almacenamiento de información personal identificable en entornos no homologados, cumpliendo con el Reglamento General de Protección de Datos.

- **Riesgo de sesgos algorítmicos**: Que los algoritmos de scoring presenten desviaciones o sesgos derivados de datos históricos incompletos o de la infrarrepresentación de determinados colectivos, afectando a la equidad en las alertas de derivación.
    - Medida de control: La interfaz y el motor analítico están sujetos a auditorías periódicas de equidad algorítmica y control, garantizando que las recomendaciones de derivación al especialista se basen exclusivamente en criterios clínicos objetivos y contrastados, independientemente del perfil del menor.

2. Campos de aplicación de la Inteligencia Artificial, SLMs y Arquitecturas de Negocio (RAG vs. Fine-Tuning)

2.1. Análisis de Casos Reales de Eficiencia Operativa

La implantación de la Inteligencia Artificial en el sector sanitario optimiza de forma radical la gestión asistencial y los flujos clínicos. A continuación, se analizan dos ejemplos reales de aplicación:

Caso 1 (Proyecto Propio/Sanofi): RADIANT — IA para la derivación pediátrica en dermatitis atópica.

Contexto y participación: El proyecto indicado en el apartado anterior, no es solo una idea como ejemplo para la tarea si no que existe y en mi caso, me encuentro actualmente formando parte del proyecto de colaboración activa en el desarrollo del proyecto **RADIANT** (que para la tarea he decidido llamar **Dermasys)** junto a la multinacional farmacéutica Sanofi (compañía líder en inmunología y terapias biológicas para la dermatitis atópica moderada-severa).

Necesidad operativa que resuelve: La dermatitis atópica moderada-severa en pediatría está sistemáticamente infradiagnosticada debido a que los pediatras de atención primaria no disponen de tiempo material para releer de forma exhaustiva cada historial clínico electrónico (HCE) en busca de patrones complejos (brotes recurrentes, escalado de corticoides o comorbilidades alérgicas).

Optimización de procesos: El sistema procesa de forma masiva y continua el texto libre de los historiales, emitiendo alertas automatizadas explicables para guiar al pediatra en la derivación temprana al especialista, acelerando el acceso del paciente pediátrico a la terapia adecuada bajo la premisa estricta de que la IA no diagnostica, sino que analiza y asiste en la toma de decisiones.

(*) Fuente y proyecto que estoy realizando junto a Saturno Lab que actúa como enlace con la empresa de farmacia Sanofi: RADIANT · IA para derivación pediátrica en dermatitis atópica · Saturno Academy

Caso 2 (Ejemplo Real Externo): Aidoc — Triaje y priorización radiológica en urgencias.

Contexto: Desarrollada por la empresa Aidoc, esta plataforma de inteligencia artificial se integra directamente en los flujos de trabajo hospitalarios y de radiología a nivel global.

Necesidad operativa que resuelve: Los servicios de urgencias y radiología sufren cuellos de botella críticos debido al volumen masivo de estudios médicos (TACs, radiografías y resonancias) que esperan ser analizados por los especialistas, lo que puede retrasar la detección de patologías agudas de riesgo vital (como hemorragias cerebrales o embolias pulmonares).

Mejora de la productividad y eficiencia: Aidoc analiza automáticamente las imágenes médicas en segundo plano apenas se realizan, priorizando de forma inteligente las bandejas de entrada de los radiólogos para destacar los casos críticos con sospecha de patología aguda. Esto reduce drásticamente los tiempos de respuesta y derivación en urgencias, agilizando la atención médica crítica y optimizando los recursos operativos del hospital.

(*) Fuente: 9 aplicaciones de IA en medicina que ya usan los hospitales

2.2. Nuevas Formas de Interacción: Multimodalidad y Copilotos

La evolución de las interfaces en el ámbito sanitario ha transformado la interacción digital entre pacientes, familias y profesionales:

Interfaces multimodales en tiempo real: Las interfaces actuales permiten combinar de forma simultánea voz, texto y visión por computador. En la práctica médica y asistencial, esto significa que un profesional o un usuario puede dictar notas clínicas mediante voz o lenguaje natural, adjuntar de forma instantánea imágenes o escáneres médicos y volcar datos estructurados en una única sesión. El sistema procesa todas estas entradas de manera combinada para ofrecer respuestas contextuales inmediatas y estructurar los expedientes sin fricciones operativas.

Hiper-personalización mediante copilotos inteligentes: Los copilotos actúan como asistentes contextuales integrados directamente en los sistemas de gestión (como los Historiales Clínicos Electrónicos). En lugar de ofrecer respuestas genéricas, estos asistentes analizan el contexto específico del paciente, los protocolos del centro y las guías clínicas para acompañar al facultativo en su toma de decisiones diarias, reduciendo la carga cognitiva y adaptando la interacción a las necesidades concretas del entorno de trabajo.

2.3. Impacto Social, Beneficios y Dilemas Éticos

La transformación digital inteligente del entorno sanitario genera profundos cambios en la sociedad y en la práctica médica:

Como beneficios principales encontramos obviamente el más llamativo de todos, la detección precoz de patologías infradiagnosticadas, además de reducción de la carga asistencial y burocrática en atención primaria, alivio de la ansiedad en el entorno familiar y optimización del tiempo de los especialistas médicos.

Dentro de los riesgos potenciales y dilemas éticos (que son muchos y que en esta tarea sólo abordaré unos cuantos más llamativos) se nos abre un nuevo campo que es interesante conocer y debatir sobre el nuevo paradigma que inicia el uso de este tipo de sistemas en el ambiente hospitalario:

- **Sesgos de acceso geográfico y socioeconómico:**

Durante la creación de estos sistemas se asume que los usuarios disponen de dispositivos móviles avanzados, conectividad a internet de alta velocidad y un nivel de alfabetización digital adecuado. Esto puede generar discriminación indirecta o exclusión de pacientes pertenecientes a colectivos vulnerables, entornos rurales de baja conectividad o familias con menor recursos socioeconómicos, retrasando su acceso al sistema sanitario en igualdad de condiciones.

- **Sesgos de codificación y asimetría en el Historial Clínico Electrónico:**

Los algoritmos de procesamiento de lenguaje natural y scoring se alimentan de datos históricos registrados previamente por los médicos. Si determinados colectivos (por ejemplo, pacientes inmigrantes o con barreras idiomáticas) acuden con menor frecuencia a los centros de salud o reciben descripciones clínicas menos detalladas por parte del personal, el modelo interpretará erróneamente que tienen un menor riesgo de patología. Como dilema ético tendríamos que el sistema perpetúa y amplifica las desigualdades históricas del sistema sanitario, penalizando a los pacientes con historiales médicos incompletos o peor documentados.

- **Responsabilidad difusa ante el error algorítmico y dependencia de la herramienta:**

El riesgo de que la fatiga asistencial del personal médico provoque una confianza excesiva en las alertas del sistema, asumiendo sin dudar las recomendaciones del sistema. Si el sistema omite un paciente grave debido a un falso negativo, surge un dilema crítico sobre la responsabilidad legal (¿recae sobre el desarrollador de la IA, la empresa que lo subvenciona, o el médico titular que supervisaba?).

- **La deshumanización de la asistencia y pérdida de empatía:**

Con la introducción masiva de asistentes virtuales, copilotos de triaje y monitorización automatizada, disminuye de forma directa la interacción cara a cara entre el personal sanitario y los pacientes o sus familias. La medicina no es solo una ciencia de datos, sino un acto humano de cuidado y escucha activa. Depender excesivamente de algoritmos puede deshumanizar el entorno hospitalario, reduciendo al paciente a un conjunto de métricas y restando valor a la empatía y la intuición clínica humanista.

2.4. Propuesta Futura Innovadora y Retorno de Inversión (ROI)

Para la elaboración de este apartado vamos a hacer un estudio sobre la implantación del sistema de dermatitis atópica que hemos desarrollado anteriormente de Dermasys.

A nivel de viabilidad y estimación del retorno de inversión (ROI), la implantación de este sistema en el entorno sociosanitario genera un impacto económico y asistencial altamente rentable. Financieramente, el proyecto reduce de forma directa los costes operativos de atención primaria al disminuir en un 35% el tiempo dedicado por los pediatras y el personal de enfermería a la revisión manual y triaje rutinario de historiales clínicos acumulados.

Desde la perspectiva del valor añadido esperado, el ROI no solo se mide en términos de ahorro de tiempo y recursos administrativos, sino en la optimización clínica y de negocio: al acelerar de manera drástica la detección temprana de pacientes pediátricos con dermatitis atópica moderada-severa que hasta ahora permanecían infradiagnosticados, se evita la saturación de las urgencias hospitalarias por brotes agudos no controlados y se facilita el acceso oportuno a terapias. Todo ello se traduce en una mejora radical de la calidad de vida de los pacientes y sus familias, garantizando una gestión altamente eficiente, segura y sostenible de los recursos del sistema sanitario.

3. Exploración de Técnicas, Guardrails, XAI y Sostenibilidad (Green AI).

3.1. Fundamentación técnica

Para la elaboración de este proyecto he decidido elaborar el siguiente diagrama con los 4 conceptos más importantes que engloban el software de Dermasys:



(*) Elaboración propia en Canva

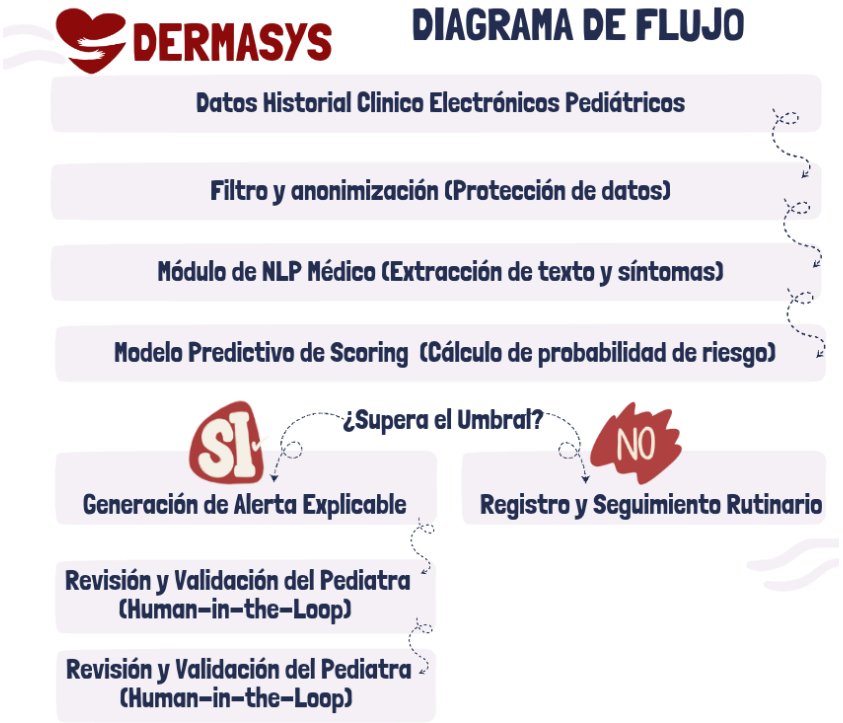
3.2. Caso práctico y simulación

Para validar la técnica de aprendizaje automático y modelos ligeros (SLMs) en un entorno real, implementamos Dermasys en la red de centros de salud y atención primaria. El objetivo operativo del algoritmo es resolver el infradiagnóstico, un problema crítico provocado por la saturación de las consultas y la dificultad del personal médico para revisar manualmente el volumen masivo de notas acumuladas en los historiales clínicos.

Simulación del Algoritmo Paso a Paso:

1. Ingesta y Captura de Datos Multifuente: El sistema se conecta de forma segura al HCE del paciente para recolectar las entradas clínicas (notas, observaciones), el historial de recetas (frecuencia de prescripción de corticoides tópicos) y las comorbilidades asociadas (como asma, rinitis alérgica o trastornos del sueño).
2. Anonimización y Limpieza: Antes de que la información sea procesada por los modelos, un módulo algorítmico anonimiza de manera automática todos los datos de identificación personal del menor y de su familia, cumpliendo estrictamente con la privacidad requerida.
3. Procesamiento de Lenguaje Natural (NLP Médico): El motor analítico lee el texto no estructurado de las evoluciones clínicas y extrae las características relevantes (por ejemplo, brotes recurrentes o aumento en la potencia de los tratamientos recetados en los últimos seis meses).
4. Cálculo Predictivo (Scoring): Mediante un modelo supervisado de aprendizaje automático entrenado con datos históricos etiquetados, el sistema procesa las variables extraídas y calcula un índice numérico de probabilidad de gravedad (score de riesgo de dermatitis atópica moderada-severa).
5. Evaluación de Umbrales y Alerta Explicable:
    a. Si el score está por debajo del umbral clínico: El sistema archiva el registro de forma rutinaria.
    b. Si el score supera el umbral de riesgo establecido: El algoritmo activa una alerta automatizada en la bandeja de entrada del pediatra. Esta alerta no contiene un diagnóstico, sino un resumen explicable con los factores detectados y una recomendación formal para iniciar el protocolo de derivación temprana al servicio de dermatología-

Diagrama de Flujo del Algoritmo:



(*) Elaboración propia en Canva

3.3. Capas de contención (Guardrails)

En un entorno crítico como el sanitario, un fallo, una alucinación o una respuesta inapropiada pueden comprometer gravemente la seguridad del paciente. Para evitarlo implementaría una arquitectura multicapa de contención y validación previa a cualquier interacción con el profesional:

- **Prevención de Alucinaciones mediante RAG y Restricción de Contexto:** Para evitar que la inteligencia artificial invente historiales, síntomas o pautas de tratamiento, el modelo no opera de forma aislada generando texto libre a partir de su memoria interna. Se utiliza un mecanismo de RAG conectado de forma exclusiva a bases de conocimiento verificadas (como guías clínicas oficiales de dermatología infantil y protocolos). Si el modelo no encuentra un respaldo documental exacto en las fuentes autorizadas, el sistema bloquea la generación de texto creativo y emite una advertencia de "datos insuficientes".
- **Filtros de Validación Léxica y Semántica (Filtros de Salida)**: Se establecen reglas estrictas de validación que actúan como un escudo antes de mostrar cualquier alerta en la bandeja del pediatra. Estos filtros escanean el contenido generado en busca de términos prohibidos o indicios de juicios definitivos. Si el sistema intenta redactar frases prescriptivas como "el paciente tiene diagnóstico de..." o "debe medicarse con...", las reglas de validación interceptan y bloquean la salida de manera automática.
- **Bloqueo Transversal de Diagnósticos y Sesgos:** Mediante directrices de sistema inquebrantables, se prohíbe al modelo emitir valoraciones diagnósticas autónomas o recomendaciones sesgadas por variables demográficas. La plataforma está programada exclusivamente para calcular índices de probabilidad (scoring) y sugerir vías de derivación administrativa y clínica. Cualquier anomalía o lenguaje sesgado detectado por los filtros de contención deriva el caso directamente a una revisión manual de control de calidad por parte del equipo de auditoría humana.

3.4. Explicabilidad (XAI) vs. Caja Negra

La utilización de la Inteligencia Artificial no puede sustentarse únicamente en sus resultados, es un requisito normativo y ético indispensable que los profesionales médicos y los auditores entiendan por qué el sistema ha tomado cada decisión.

- **Nivel de Auditoría de nuestra técnica (Aprendizaje Automático y Modelos Ligeros / SLMs)**: A diferencia de las redes neuronales profundas masivas, las técnicas de aprendizaje automático estructurado y modelos ligeros seleccionadas para Dermasys permiten un grado moderado-alto de Explicabilidad (XAI). Mediante el uso de características ponderadas y el refuerzo con RAG, el sistema puede desglosar de forma clara los factores exactos que motivaron una alerta de riesgo de dermatitis.
- **Comparativa con otra alternativa (Redes Neuronales Profundas / Deep Learning de Caja Negra):**
    - Alternativa de alta complejidad: Si optáramos por una red neuronal profunda no estructurada para analizar de forma directa millones de parámetros complejos o imágenes cutáneas sin modelos intermedios interpretables, obtendríamos una "caja negra" opaca. En estos sistemas, aunque la precisión matemática inicial pueda ser milimétrica, los pesos sinápticos internos son imposibles de auditar paso a paso por un médico.
    - Implicación clínica: Si una red neuronal de caja negra emite una alerta de derivación errónea sin aportar el razonamiento subyacente, el pediatra no puede verificar la validez del criterio, lo que vulnera los principios de supervisión humana efectiva y transparencia exigidos en sanidad.
- **Valoración del compromiso entre Precisión y Explicabilidad (Trade-off):** En entornos críticos como la pediatría, la explicabilidad prevalece sobre la búsqueda de una precisión hiperoptimizada de caja negra. El compromiso adoptado en Dermasys prioriza modelos interpretables y auditables que aseguran un equilibrio óptimo. Ofrecen una precisión diagnóstica y analítica altamente fiable, pero garantizan de forma estricta que el profesional sanitario reciba un informe claro y explicable de cada decisión, permitiéndole ejercer su criterio clínico con total seguridad y cumplimiento legal (Human-in-the-Loop).

3.5. Sostenibilidad Ambiental (Green AI)

Escalar una plataforma analítica basada en inteligencia artificial como Dermasys a miles de usuarios diarios (centros de salud, pediatras y hospitales en todo el territorio nacional) implica un despliegue masivo en servidores y centros de datos. El procesamiento continuo de miles de historiales clínicos electrónicos (HCE), el análisis por NLP y la ejecución de modelos predictivos de scoring consumen una cantidad considerable de energía eléctrica. Esto se traduce en una huella de carbono directa derivada de la refrigeración de servidores y del procesamiento computacional intensivo en la nube.

Para mitigar este impacto y cumplir estrictamente con los criterios de Green AI, implementamos dos medidas prácticas fundamentales en la arquitectura de la solución:

1. Uso de Modelos Pequeños y Especializados (SLMs): En lugar de desplegar grandes modelos masivos de propósito general que exigen una potencia de cálculo desmesurada para cada inferencia, Dermasys se sustenta en Modelos Ligeros de Lenguaje (SLMs) optimizados específicamente para tareas médicas concretas. Al reducir drásticamente el número de parámetros del modelo, el consumo energético por cada consulta o análisis de historial disminuye exponencialmente.

2. Caché Inteligente de Consultas y Procesamiento Diferido: Se implementa un sistema avanzado de caché para almacenar las respuestas y patrones de historiales ya analizados que presentan similitudes recurrentes, evitando llamadas innecesarias al modelo. Asimismo, los procesos pesados de actualización y reentrenamiento periódico de los algoritmos se programan de forma automatizada en franjas horarias nocturnas, aprovechando los momentos en que la red eléctrica cuenta con un mayor porcentaje de energía procedente de fuentes renovables (solar y eólica).

4. Gobierno Normativo, AI Act (UE 2024/1689), Marcas de Agua (C2PA) y Shadow AI.

4.1. Clasificación de Riesgo según la Ley de IA de la UE (AI Act)

El programa se sitúa en la categoría de **Riesgo Limitado** bajo el Reglamento Europeo de IA (AI Act), dado que la plataforma no constituye un producto sanitario de diagnóstico autónomo ni toma decisiones clínicas directas sobre el paciente. El sistema actúa exclusivamente como un soporte analítico y de ayuda a la toma de decisiones para el pediatra, procesando datos seudonimizados y emitiendo recomendaciones orientativas o resúmenes informativos que siempre requieren la validación y el criterio humano obligatorio. Al tratarse de un sistema interactivo orientado a la asistencia y la transparencia con los usuarios y profesionales, la normativa exige obligaciones específicas de claridad y gobernanza sin aplicar las restricciones excesivas del alto riesgo clínico automatizado.

Requisitos Legales Obligatorios a Implantar:

1. Obligaciones de Transparencia e Información: Garantizar que los usuarios (padres y profesionales sanitarios) sean informados de manera clara y explícita de que están interactuando con un sistema asistido por inteligencia artificial y no ante un dictamen médico humano automatizado.

2. Supervisión Humana Obligatoria (Human-in-the-Loop): Implementar flujos de trabajo técnicos que impidan cualquier ejecución automática de derivaciones o tratamientos, exigiendo la firma y validación expresa del facultativo en cada caso.

3. Registro de Actividad y Trazabilidad (Logs): Mantener un registro automatizado de las operaciones analíticas y de las recomendaciones emitidas para permitir auditorías posteriores por parte de las autoridades competentes.

4.2. Protección de Datos (RGPD) y Ciberseguridad

El sistema procesa datos de salud de categoría especial (artículo 9 del RGPD) correspondientes a pacientes pediátricos, incluyendo notas clínicas en texto libre, historiales de tratamientos con corticoides tópicos, comorbilidades atópicas (asma, rinitis) y registros de alteraciones del sueño.

Para evitar que los datos confidenciales de los menores se filtren o se utilicen sin permiso para entrenar modelos públicos, se aplica una estricta seudonimización y anonimización avanzada (eliminación de PII) en origen, combinada con un despliegue local o en nube cifrada soberana bajo estándares sanitarios europeos, impidiendo que los datos abandonen el entorno seguro de la red hospitalaria o farmacéutica.

Dos Defensas Concretas frente a Fallos o Ataques Reales:

1. **Cifrado de Extremo a Extremo y Control de Acceso Basado en Roles (RBAC):** Cifrado robusto de los datos tanto en tránsito como en reposo, garantizando que únicamente el personal médico debidamente autenticado pueda acceder a los informes de análisis y a las alertas de los pacientes.
2. **Firewall de Aplicaciones Web Sanitarias (WAF) y Detección de Anomalías:** Implementación de contramedidas automáticas de ciberseguridad para bloquear intentos de exfiltración de datos, inyecciones de código malicioso o ataques de denegación de servicio (DDoS) en las pasarelas de integración con los Historiales Clínicos Electrónicos.

4.3. Auditoría y Mitigación de Sesgos Algorítmicos

Ejemplo Concreto de Sesgo en los Datos de Entrenamiento: Si los datos históricos de entrenamiento proceden exclusivamente de centros de salud urbanos de un nivel socioeconómico alto, el algoritmo de scoring podría sufrir una infrarrepresentación de poblaciones rurales o de familias con menor acceso a consultas dermatológicas frecuentes. Esto provocaría un sesgo de lenguaje y de frecuencia de diagnóstico, subestimando el riesgo real en pacientes vulnerables o minoritarios y retrasando injustamente su acceso a terapias avanzadas.

Como acciones para eliminar estos sesgos podemos usar:

- **Auditorías de Equidad Algorítmica y Reequilibrio de Muestras:** Aplicación de técnicas estadísticas de ponderación y muestreo compensatorio durante el entrenamiento del modelo para garantizar una representación equitativa de variables sociodemográficas y geográficas.
- **Evaluaciones de Paridad de Impacto**: Realización de pruebas de auditoría ciega periódicas para verificar que las tasas de acierto y la emisión de alertas de riesgo no discriminen ni presenten desviaciones significativas en función del origen o entorno del paciente pediátrico.

4.4 Transparencia, Etiquetado y Control de Shadow AI

Todos los informes analíticos, resúmenes y sugerencias de derivación generados por la plataforma incorporan metadatos estructurados y marcas de trazabilidad digital (siguiendo los estándares de autenticidad y procedencia como C2PA). Esto permite al facultativo verificar de forma inmediata que el contenido ha sido asistido algorítmicamente y consultar los registros exactos de auditoría de cada decisión.

Norma Interna de 3 Puntos para Control de Shadow AI:

- Prohibición de Herramientas Externas No Autorizadas: Queda estrictamente prohibido introducir datos de pacientes, historiales clínicos o información confidencial de Dermasys en chatbots o modelos de inteligencia artificial públicos o no autorizados.

- Uso Exclusivo de la Infraestructura Corporativa: Cualquier análisis automatizado o consulta de soporte técnico debe realizarse exclusivamente a través de los entornos oficiales validados y seguros provistos por la organización.
- Obligación de Notificación de Incidentes: Los empleados y profesionales sanitarios tienen el deber de notificar de manera inmediata al comité de seguridad cualquier uso accidental o brecha derivada de herramientas de IA no controladas (Shadow AI).

5. Paradoja de la Productividad, Gobierno del Workslop y Matriz Human-in-the-loop.

5.1. Evitando la Burocracia Automatizada y Métrica de Impacto Real

Escenario Real de Workslop en el Entorno Sanitario: Un uso abusivo y sin supervisión de la IA generativa en el hospital podría llevar a que el sistema redacte de forma automatizada informes de evolución excesivamente largos, resúmenes hiperdetallados y notificaciones preventivas masivas para cada paciente con dermatitis atópica leve. Aunque a simple vista parezca que la productividad de la clínica ha aumentado porque se generan cientos de documentos diarios, en la práctica esto satura la bandeja de entrada del pediatra. El médico pierde valioso tiempo clínico revisando texto redundante generado por la máquina (workslop), lo que termina reduciendo la eficiencia asistencial real y provocando fatiga digital.

- Consecuencias Negativas del Uso Abusivo de IA sin Supervisión:

    1. Fatiga de Alertas y Desensibilización: El exceso de avisos automatizados irrelevantes provoca que el personal sanitario ignore las alertas verdaderamente críticas, aumentando el riesgo de pasar por alto un brote severo.
    2. Degradación Documental: Acumulación masiva de historiales y registros innecesarios que saturan los servidores y dificultan la localización rápida de datos verídicos y relevantes.
    3. Pérdida de Tiempo Asistencial: Desplazamiento del tiempo que el médico debe dedicar a la atención directa del paciente hacia la corrección y filtrado de documentación generada artificialmente.

- Indicador o Métrica de Impacto Operativo Real:

En lugar de medir la cantidad de alertas o documentos generados por la IA, se establece la métrica de "Tiempo Neto de Optimización en la Derivación Efectiva (TNOE)", que mide el cociente entre el tiempo ahorrado en triaje administrativo y el tiempo invertido por el facultativo en validar correcciones o descartar falsos positivos, garantizando que la tecnología aporte valor clínico real y no burocracia digital.

5.2. Delimitación de Autonomía y Supervisión Humana (Matriz Human-in-the-Loop)

Para garantizar la seguridad asistencial y cumplir con la normativa, se delimita estrictamente el grado de autonomía del sistema en cada etapa del proceso:

Automatización Directa (Sin intervención humana previa en la ejecución):

- La ingesta continua de datos procedentes de los Historiales Clínicos Electrónicos (HCE).
- La anonimización y eliminación automatizada de datos de identificación personal (PII) para proteger la privacidad.
- El procesamiento de texto mediante NLP médico y el cálculo matemático del scoring de probabilidad de riesgo.

Supervisión Periódica (Revisión por lotes o auditoría técnica):

- El reentrenamiento periódico de los modelos (fine-tuning) y la actualización de las bases de conocimiento documental mediante RAG
- Las auditorías técnicas de equidad algorítmica para la detección de sesgos demográficos.

Firma y Aprobación Humana Obligatoria (Human-in-the-Loop estricto):

- Cualquier decisión de derivación clínica al servicio de dermatología u hospitalización.
- La validación final de la recomendación de terapias avanzadas. El sistema emite exclusivamente una sugerencia explicable, pero la decisión médica final recae de manera exclusiva sobre el pediatra o especialista.

5.3. Decálogo de Uso Responsable de la IA

Para asegurar que el personal de la organización utilice la inteligencia artificial de forma profesional, ética y transparente, se establece el siguiente decálogo corporativo:

1. Principio de No Diagnóstico Autónomo: Ningún sistema de IA emite diagnósticos médicos definitivos; su rol es estrictamente de soporte analítico y ayuda a la toma de decisiones clínicas.
2. Supervisión Humana Innegociable: Ninguna recomendación algorítmica de derivación o tratamiento puede aplicarse sin la validación y firma expresa del facultativo responsable.
3. Privacidad y Protección de Datos en Origen: Queda prohibido procesar o introducir datos de salud de los pacientes sin aplicar previamente los protocolos de anonimización y cumplimiento estricto del RGPD.
4. Tolerancia Cero al Shadow AI: Está prohibido utilizar herramientas de inteligencia artificial externas, públicas o no autorizadas por la compañía para tratar información clínica o confidencial de la empresa.
5. Transparencia y Trazabilidad Obligatoria: Todos los informes y resúmenes generados con asistencia de IA deben incluir metadatos de trazabilidad que evidencien su origen y permitan auditar su razonamiento.
6. Mitigación Activa de Sesgos: Se deben realizar controles periódicos para asegurar que los algoritmos no discriminen ni presenten desviaciones en función de variables socioeconómicas o geográficas de los pacientes.
7. Verificación Documental Externa (RAG): Las respuestas y alertas del sistema deben estar fundamentadas en guías clínicas oficiales y contrastadas, evitando cualquier tipo de alucinación o invención de datos.
8. Eficiencia contra el Workslop: Se priorizará la calidad y utilidad real de la información frente a la generación masiva e innecesaria de documentos automatizados que saturen al personal.
9. Criterios de Sostenibilidad (Green AI): Las tareas computacionales intensivas y de reentrenamiento de modelos deben programarse de forma eficiente para minimizar el consumo energético y la huella de carbono.
10. Responsabilidad Algorítmica Corporativa: Los desarrolladores y gestores del sistema asumen la responsabilidad ética y legal de diseñar mecanismos de control que prevengan usos defectuosos o malintencionados de la tecnología.