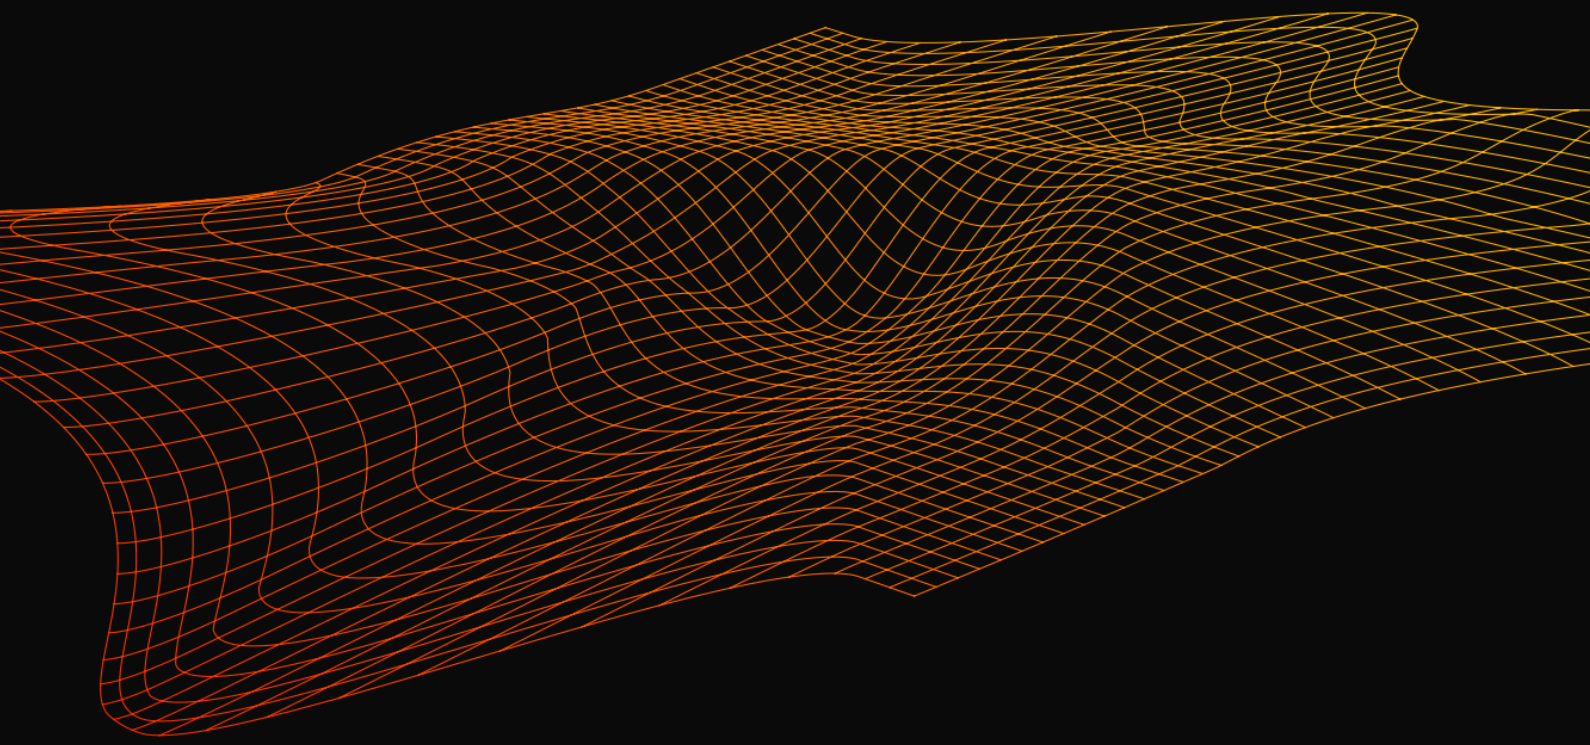
TAREA UNIDAD 1

Amazon Rekognition Vs Google Cloud Vision

Programación en Inteligencia Artificial (PIA)



Inteligencia Artificial y Big Data

Ana Isabel Navarro Jiménez

ÍNDICE

1. Propuesta de proyecto.....3
Problemática o necesidad que pretende resolver.....3
Los usuarios o entidades a los que estaría destinado.....3
Cómo puede utilizarse la IA y el procesamiento de imágenes para aportar valor..... 3
2. Objetivos.....3
Objetivo principal.....3
Objetivos secundarios o de mejora (deseables):..... 3
3. Análisis de riesgos..... 4
4. Marco legal y uso responsable de la ia.....4
5. Análisis de requisitos.....5
Requisitos funcionales:..... 5
Requisitos no funcionales:..... 6
6. Planificación del proyecto.....6
Ciclo de desarrollo general:.....6
Ciclo específico de la Inteligencia Artificial:..... 7
7. Tecnologías para el desarrollo.....7
8. Perfiles profesionales..... 8
9. Caso práctico - Amazon Rekognition vs Google Cloud Vision..... 9
Imagen 1: Retrato.....9
Imagen 2: Grupo de personas..... 10
Imagen 3: Escena con múltiples objetos..... 11
Imagen 4: Imagen con texto.....12
Imagen 5: Imagen de especial dificultad.....13
Imagen 6: Caso relacionado con su proyecto.....14
Imagen 7: Extra interesante de ser comentada para el proyecto..... 15
C) Análisis de la respuesta JSON.....16
Explicación de extracción y utilización automática mediante programación.....16
D) Conclusiones.....17

1. Propuesta de proyecto

Problemática o necesidad que pretende resolver.
El proyecto nace de una necesidad muy común como lo es la intranquilidad que sentimos los dueños de mascotas (especialmente perros y gatos) cuando los dejamos solos en casa por trabajo o viajes. Con este proyecto se busca implementar una detección inteligente del comportamiento animal mediante el uso de IA para monitorear su comportamiento diario, comprobando si usan el arenero, si están estresados, si se están en zonas no permitidas.. etc.

Los usuarios o entidades a los que estaría destinado
Inicialmente, está pensado para cualquier usuario que quiera vigilar a sus perros o gatos en su propio hogar. Sin embargo, el sistema es altamente escalable. A medio y largo plazo, los destinatarios pueden ampliarse a granjas, refugios y protectoras de animales, o incluso parques zoológicos que necesiten monitorear animales exóticos.

Cómo puede utilizarse la IA y el procesamiento de imágenes para aportar valor.
Aquí es donde el proyecto se desmarca de las cámaras de vigilancia tradicionales. No se trataría de un modelo genérico que simplemente detecte "gato" o "perro". El valor añadido está en entrenar o ajustar el modelo con imágenes de la propia mascota del usuario. La IA no solo dirá "hay un perro en el sofá", sino "Kali está en una zona prohibida" o "Bimba ha bebido agua tres veces hoy". Transformamos un flujo de vídeo en un panel de control inteligente y personalizado para cada mascota y a gusto del usuario.

2. Objetivos

Objetivo principal
El objetivo principal del proyecto es desarrollar un sistema de visión artificial capaz de identificar de manera unívoca a las mascotas (por su nombre) y clasificar sus acciones en tiempo real. El sistema debe ser capaz de monitorizar su situación vital (comer, beber, usar el arenero, estado de ánimo) y emitir alertas inmediatas si la mascota accede a zonas restringidas, hace destrozos o intenta escaparse de casa.

Objetivos secundarios o de mejora (deseables):

- Escalabilidad a otras especies: Extender el modelo para reconocer aves, reptiles, grandes mamíferos, animales exóticos…
- Gestión de multitudes para zoos o refugios : Adaptar el sistema para que cuente individuos en recintos grandes, ayudando a gestionar grandes grupos de animales.
- Integración de hábitats: Monitorizar el comportamiento de un animal nuevo cuando se introduce en una manada o recinto, para detectar signos tempranos de rechazo o agresividad.
- Estudio de comportamiento: Para investigaciones en las que se necesite comprobar si un animal está listo para ser devuelto a la naturaleza en centros de rescate mediante análisis en sus comportamientos.

3. Análisis de riesgos

Dentro de los riesgos podemos encontrar:

Riesgos	Explicación	Mitigación
Técnicos	En lugares grandes se pueden crear puntos ciegos en los que no veamos al animal. Si no hay suficientes cámaras, perdemos el seguimiento completo.	Diseñar el sistema para que sea compatible con cámaras económicas para que al usuario le resulte fácil cubrir toda la casa, o hacer un estudio previo de las zonas para asegurarnos de controlar todos los lugares necesarios.
Económicos	El coste inicial de comprar varias cámaras puede frenar a los usuarios.	Ofrecer el software como un servicio independiente, permitiendo que el usuario use las cámaras que ya tenga.
Organizativos	El modelo necesita buenas fotos iniciales. Si el usuario sube tres fotos borrosas, el sistema no aprenderá a distinguir a su mascota correctamente.	Crear un proceso guiado en la aplicación que exija un vídeo de 30 segundos del animal desde varios ángulos o incluir en el software un análisis de imágenes que determine la calidad y solicite más imágenes al usuario si no son válidas.
Relacionados con los datos y predicciones	La existencia de mascotas idénticas (por ejemplo dos gatos completamente negros en la misma casa) provocará falsos positivos y confusión de identidades.	Dejar esta limitación muy clara en los términos y condiciones de uso. Como mejora técnica, se puede pedir a los dueños que pongan collares de colores distintos para ayudar a la IA. Es algo que se debe dejar indicado claramente antes de forma clara para el usuario.
Éticos	Las cámaras grabarán el interior de un hogar afectando a la privacidad.	Asegurar que las imágenes se descartan inmediatamente tras extraer los metadatos (la acción de la mascota) y nunca guardar los datos privados del usuario.

4. Marco legal y uso responsable de la ia

En cuanto al análisis de las implicaciones legales y normativas, al tratarse de un proyecto donde instalamos cámaras dentro del hogar, es de vital importancia tener completamente controlada la privacidad de los usuarios.

Aunque inicialmente el software se encargará de registrar el comportamiento animal, y pese a que la legislación española reconoce a los animales como "seres sintientes" (gracias a la reforma del Código Civil y la Ley de Protección Animal), esto no les otorga personalidad jurídica ni derechos fundamentales como la privacidad o la protección de datos personales. Sin embargo, es completamente inevitable que las cámaras graben a las personas, dueños, familiares u otros. Por lo que en el momento en que captamos personas, el proyecto tiene que cumplir con el Reglamento General de Protección de Datos (RGPD) a nivel europeo y con la Ley Orgánica 3/2018 (LOPD-GDD) en España.

Legalmente, aplicaremos el cumplimiento legal desde el diseño de la aplicación. Básicamente, cuando el usuario se baje la aplicación y se registre, se le solicitará un consentimiento informado claro, entendible y extenso. El usuario debe conocer exactamente para qué vamos a usar esas imágenes, que riesgos puede llevar y qué medidas debe tener en cuenta.

En cuanto a la clasificación de riesgo según el AI Act. Si miramos la Ley Europea de Inteligencia Artificial (AI Act) para el proyecto, entraríamos directamente en la categoría de **Riesgo Mínimo o Nulo**. Ya que no estamos creando un sistema de vigilancia biométrica para humanos, ni una IA que manipule el comportamiento o decida de forma crítica. Como es una aplicación de uso doméstico pensada exclusivamente para el ocio y el cuidado animal, la ley nos permite comercializar libremente, siempre que respetemos las normas de privacidad.

En cuanto a las cuestiones específicas aplicadas a nuestro caso, para asegurarnos de que el sistema sea ético y funcione bien en el mundo real, podemos analizar estos problemas en soluciones concretas para el proyecto:

- **Protección de datos y tratamiento de imágenes de personas:** Como mandar vídeos del interior de una casa a un servidor externo conlleva un gran riesgo, la solución técnica es que la IA procese la imagen primero de forma local. El sistema detecta las caras de las personas y las difumina automáticamente antes de subir nada a la nube. Así, al servidor solo llega la información de lo que hace la mascota y la privacidad de los dueños queda blindada.
- **Transparencia:** Hay que ser muy honestos con el usuario desde el principio. En la app dejaremos claro con un aviso que la IA puede equivocarse y que es solo una ayuda extra. No sirve como excusa para desentenderse de sus mascotas. El dueño sigue siendo el único responsable del cuidado y bienestar. El sistema no se hace responsable del mal uso que le de el usuario.
- **Posibles sesgos:** Si entrenamos a la IA solo con fotos de animales de tonos claros o con buena luz, el modelo se volverá sesgado. El ejemplo más típico en visión artificial es que al sistema le cueste muchísimo detectar mascotas de pelo completamente negro, o que falle en cuanto atardece y la luz baja.
- **Consecuencias de los errores del sistema:** Si la IA comete errores por culpa de estos sesgos o de la iluminación, no derivaría en acciones legales, pero sí afecta a la experiencia final del cliente. Por lo que es importante informar de dichos sesgos al usuario. Ejemplos:
    - Falsos positivos: La cámara confunde un cojín de pelo con la mascota, si se tuviera esa zona delimitada como zona prohibida, al detectarlo sobre el sofá, el sistema mandaría un mensaje urgente al móvil.
    - Falsos negativos: La mascota se escapa por la terraza, pero al tener una iluminación deficiente, o un ángulo sin visión, la cámara no lo detecta.

5. Análisis de requisitos

Requisitos funcionales:

- El sistema debe permitir el registro y entrenamiento personalizado mediante la subida de un vídeo o fotos de la mascota.
- Debe detectar y etiquetar a la mascota de forma correcta por su nombre.
- Debe clasificar acciones clave: comer, beber, dormir, jugar, morder, arañar, defecar, orinar, vomitar..
- El usuario debe poder definir en la pantalla "zonas prohibidas" y el sistema debe enviar una notificación si la mascota entra ahí.
- Debe ser capaz de monitorizar el comportamiento de la mascota en función a métricas medidas durante periodos de tiempo, etiquetando al animal por su comportamiento, pudiendo determinar situaciones en las que el animal se aísle o actúe de forma errática. Esto permite al sistema establecer momentos en los que la mascota se encuentra mal o actúa de forma diferente, especialmente útil en situaciones en las que peligra su vida.

- Debe ser capaz de analizar los comportamientos de la mascota entrenando al modelo con situaciones permitidas y no permitidas, como por ejemplo, arañar el sofá, morder los muebles, orinar fuera de su zona y el usuario debe poder indicar en un menú de opciones cuales son las actitudes en las que quiere ser notificado cuando su mascota las realice.

Requisitos no funcionales:

- Tiempo de respuesta: Las alertas de escape o peligro deben llegar al teléfono en menos de 3 segundos (baja latencia).
- Disponibilidad: El sistema debe operar 24/7.
- Privacidad y seguridad: Todo el tráfico de vídeo debe ir encriptado de extremo a extremo.
- Usabilidad: La interfaz debe ser muy intuitiva y no requerir conocimientos técnicos.

6. Planificación del proyecto

Ciclo de desarrollo general:

Análisis: En esta fase se realiza la toma de requisitos funcionales y no funcionales del proyecto y el estudio de viabilidad. Especialmente es importante identificar las necesidades que pueda tener el usuario, como la monitorización de las métricas temporales que se van a analizar en las mascotas o el envío de alertas críticas. Se establecen los requerimientos para el estudio previo de las estancias donde estarán las cámaras, asegurando que el usuario sepa en todo momento cómo realizar una cobertura completa de las zonas sin puntos ciegos. Además, se lleva a cabo un estudio exhaustivo de la competencia para definir factores diferenciadores frente a las cámaras comerciales existentes de monitorización y control animal.

Diseño: Durante el diseño se crea la arquitectura de software, se define la lógica para el procesamiento de las métricas temporales de comportamiento y se estructura la base de datos para almacenar el historial vital de la mascota. Además, se diseña la interfaz centrándose en la usabilidad la cual debe ser una pantalla muy intuitiva donde el usuario pueda dibujar las "zonas prohibidas" con el dedo y un menú de opciones claro para elegir de qué actitudes concretas quiere que se le notifique (arañar, morder, orinar fuera).

Desarrollo: Se realiza la programación del *backend* (gestión de usuarios y aseguramiento del tráfico encriptado de extremo a extremo) y del *frontend* (app móvil). Aquí también se integra en el software el proceso de validación de imágenes durante el registro: si las fotos iniciales o el vídeo de 30 segundos son borrosos, el sistema pide automáticamente al usuario que suba material de mejor calidad.

Pruebas: Testeo unitario de la aplicación y pruebas de estrés con múltiples cámaras emitiendo a la vez. Se miden estrictamente los tiempos de respuesta para garantizar que el sistema cumple el requisito de baja latencia: las alertas deben llegar al móvil en menos de 3 segundos.

Despliegue: Puesta en producción en servidores en la nube para asegurar que el sistema esté disponible 24/7 y publicación de la aplicación en las tiendas oficiales (App Store y Google Play).

Mantenimiento: Corrección de errores y bugs, actualizaciones del sistema operativo y preparación de la base técnica para futuras mejoras, como la escalabilidad a refugios o zoológicos.

Ciclo específico de la Inteligencia Artificial:
Obtención y preparación de datos: Comenzaremos con la creación de un dataset inicial genérico con miles de fotos de perros y gatos en entornos domésticos haciendo cosas comunes. Es importante utilizar diferentes razas para no sesgar al modelo.

Selección de modelo: Para determinar qué modelo debemos elegir debemos asegurarnos de que posea una arquitectura de detección de objetos rápida y un modelo de reconocimiento de acciones que permita alimentar su entrenamiento con animales. Además, el modelo debe ser capaz de detectar a las personas y pixelar las caras para asegurarnos de cumplir la ley de protección de datos.

Entrenamiento: Pre-entrenar el modelo con el dataset genérico. Crear un flujo de acción para que cuando un usuario nuevo suba las fotos de su mascota, el sistema reentrene una capa final específica para él. Permitiendo así que cada mascota sea diferenciada de forma inequívoca.

Evaluación: Medir la precisión y sensibilidad , especialmente para evitar los falsos negativos.

Despliegue: Montar el modelo mediante una API en la nube que reciba los fotogramas clave de las cámaras.

Monitorización: Controlar la modificación de los datos de las mascotas. Las mascotas crecen (especialmente los cachorros); el sistema debe pedir al usuario que actualice las fotos si detecta que la precisión está bajando.

7. Tecnologías para el desarrollo

Tras analizar las tecnologías disponibles para llevar a cabo el proyecto, se puede considerar utilizar las siguientes herramientas:

Lenguajes de programación:

- Python: Es el estándar indiscutible para IA y ciencia de datos. Lo utilizaremos para todo el *backend* de procesamiento, el entrenamiento de los modelos y la inferencia en tiempo real.

Librerías y herramientas de IA:

- OpenCV:Es una herramienta fundamental. La usaremos para preprocesar los vídeos, extraer fotogramas (frames), detectar movimiento inicial (para evitar que la IA analice un vídeo estático donde no ocurre nada) y difuminar rostros humanos por privacidad.
- YOLO (You Only Look Once): Es una arquitectura excelente para la detección de objetos en tiempo real. Resulta ideal para localizar a la mascota rápidamente en cualquier punto del encuadre.
- PyTorch / TensorFlow: Las utilizaremos para afinar y entrenar los modelos personalizados de clasificación y reconocimiento de acciones.

Servicios Cloud (Amazon Rekognition vs Google Cloud Vision):

Aunque estas API son excelentes para categorización general ("esto es un gato" o "esto es un salón"), en nuestro proyecto necesitamos identificar de forma unívoca a la mascota del usuario frente a otras. Por ello, usaremos plataformas orientadas a modelos personalizados como AWS SageMaker o Google Vertex AI para orquestar nuestros propios modelos basados en YOLO. Dejaremos servicios como Amazon Rekognition únicamente para un filtrado previo rápido (por ejemplo, descartar fotogramas donde solo aparezcan personas y no haya animales).

8. Perfiles profesionales

Data Scientist / ML Engineer (Ingeniero de Machine Learning):

- Funciones: Seleccionar, entrenar y optimizar los modelos de visión artificial (YOLO, clasificación).
- Fases: Análisis, Desarrollo IA, pruebas y monitorización.
- Aportación: Es el cerebro del proyecto; asegura que el sistema sepa distinguir al "gato Garfield" de un cojín naranja.

Computer Vision Engineer (Ingeniero de Visión Artificial):

- Funciones: Trabajar con OpenCV para limpiar las imágenes, gestionar los streams de vídeo de las cámaras, calcular las "zonas prohibidas" dibujadas por el usuario.
- Fases: Diseño, desarrollo, pruebas.
- Aportación: Hace que el vídeo llegue al modelo de IA en el formato perfecto y gestiona la lógica espacial de la imagen.

Backend Developer y Cloud Architect:

- Funciones: Crear la API que conecta la app con los modelos de IA, gestionar las bases de datos y levantar la infraestructura en AWS/Google Cloud.
- Fases: Diseño, desarrollo, despliegue, mantenimiento.
- Aportación: Asegura que el sistema sea escalable y no se caiga si mil usuarios conectan sus cámaras a la vez.

Mobile/Frontend Developer:

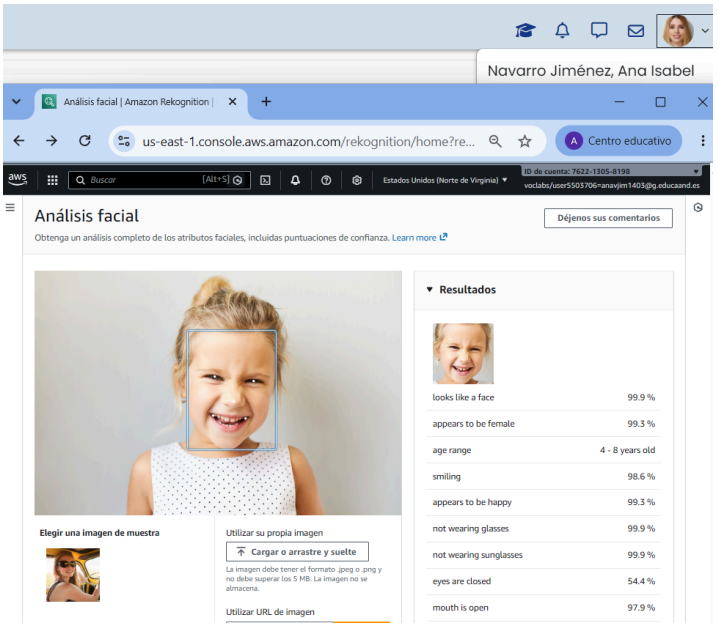
- Funciones: Desarrollar la aplicación donde el usuario ve a sus mascotas y recibe las notificaciones.
- Fases: Diseño, desarrollo, pruebas.
- Aportación: Crea la cara visible del proyecto. Una IA excelente no sirve de nada si el usuario no sabe usar la app.

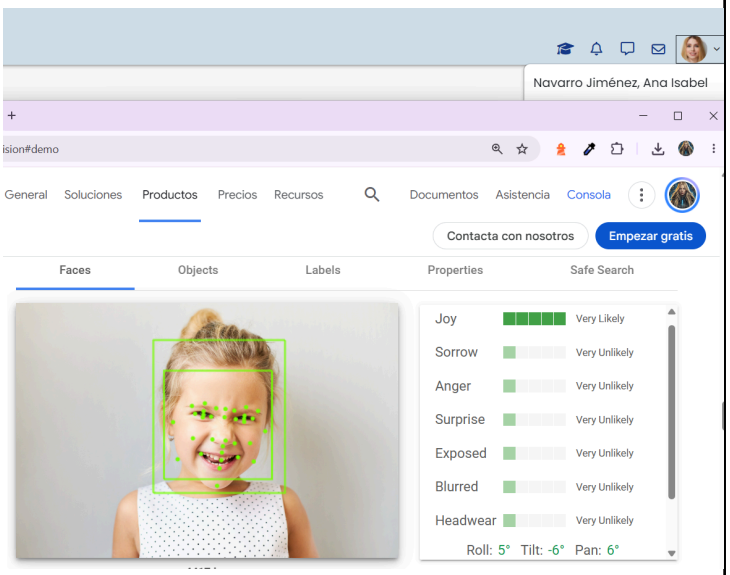
9. Caso práctico - Amazon Rekognition vs Google Cloud Vision

(*) Todas las imágenes han sido obtenidas de la web libre *https://www.magnific.com/es/imagenes* Y para todas ellas se ha usado la aplicación *https://json.onlineviewer.net/* de forma online para leer los json que se han obtenido en cada búsqueda y que se ha utilizado para analizar y comparar los resultados

Amazon Rekognition	Google Cloud Vision

Imagen 1: Retrato
Imagen de Magnific (Libre) | Imagen | Ha sido seleccionada para demostrar la alegría en una niña de forma clara





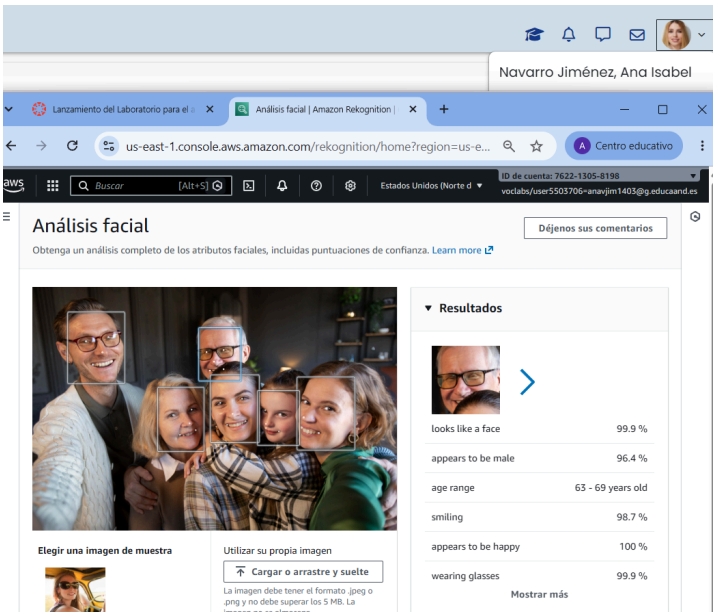
B. Análisis y Comparación de Resultados
Como podemos ver, ambos modelos detectan la cara con un 99% de seguridad y coinciden plenamente en que la niña está alegre. Sin embargo, tienen diferencias llamativas en su forma de analizar.

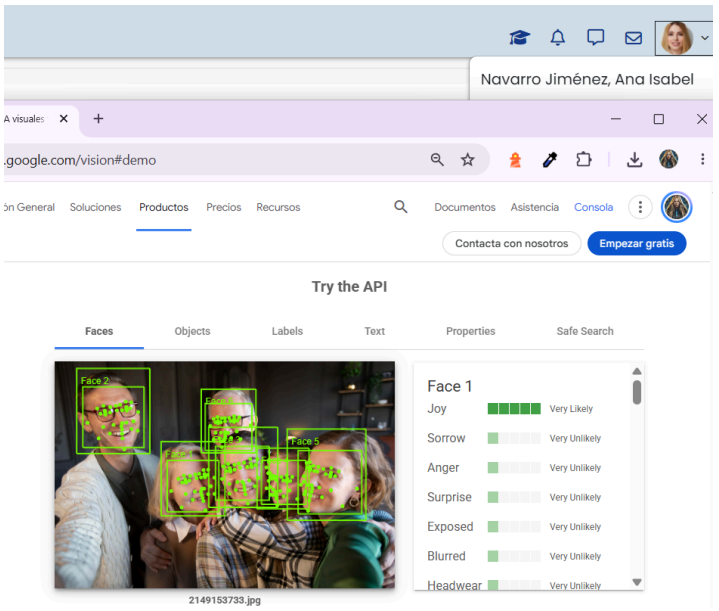
Por un lado, AWS hace un análisis muy directo y cuantitativo. Te da datos concretos sobre el físico con porcentajes exactos de certeza: estima que la niña tiene entre 4 y 8 años, indica el género, detecta si lleva gafas y señala que tiene la boca abierta.

Google Cloud Vision, en cambio, adopta una postura más reservada y no muestra la edad ni el sexo en su análisis facial básico. Prefiere evaluar la emoción usando escalas de texto (como "Very Likely" para la alegría) y medir parámetros técnicos como la inclinación de la cabeza. Lo interesante aparece al revisar el JSON completo: aunque no da un dato demográfico directo, Google deduce la edad a través del contexto visual de la escena, identificando etiquetas como "Child", "Toddler", "Baby & Toddler Clothing", el pelo rubio e incluso el estampado de lunares de la ropa ("Polka dot"). El punto flojo lo encontramos en AWS, que muestra dudas al analizar si los ojos están cerrados o abiertos, asignando una confianza bastante baja del 54,4%.

Por lo tanto para esta imagen, AWS destaca por ofrecer un desglose detallado sobre los rasgos de la cara, mientras que Google es más prudente con la demografía facial, pero lo compensa analizando la vestimenta y el entorno para entender quién protagoniza la imagen.

Imagen 2: Grupo de personas
Imagen de Magnific (Libre) | Imagen | Ha sido seleccionada para analizar un grupo de personas con diferentes características faciales y edades una de ellas (el anciano) oculto para ver hasta donde llega los modelos





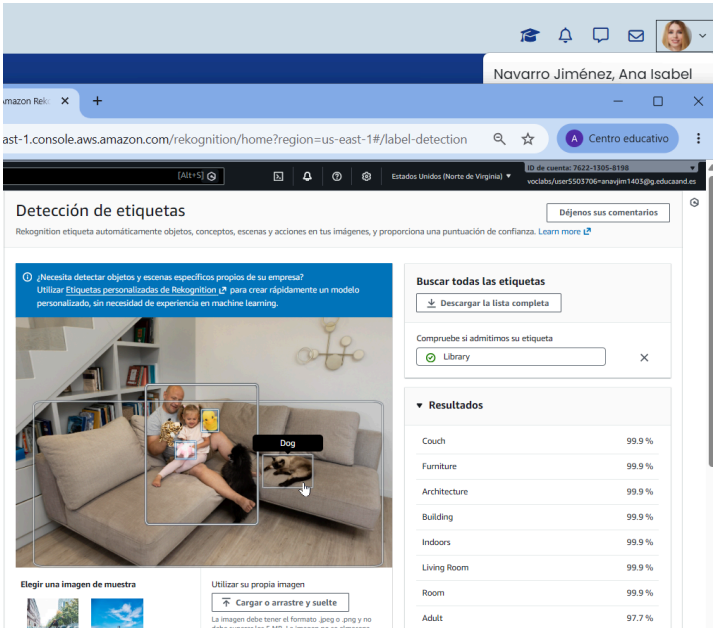
B. Análisis y Comparación de Resultados
En esta imagen de grupo, los dos modelos funcionan de forma similar al localizar a las seis personas que aparecen, sin omitir a ninguna. Ambos coinciden además en captar la atmósfera de la escena, identificando la alegría como la emoción predominante en el grupo.

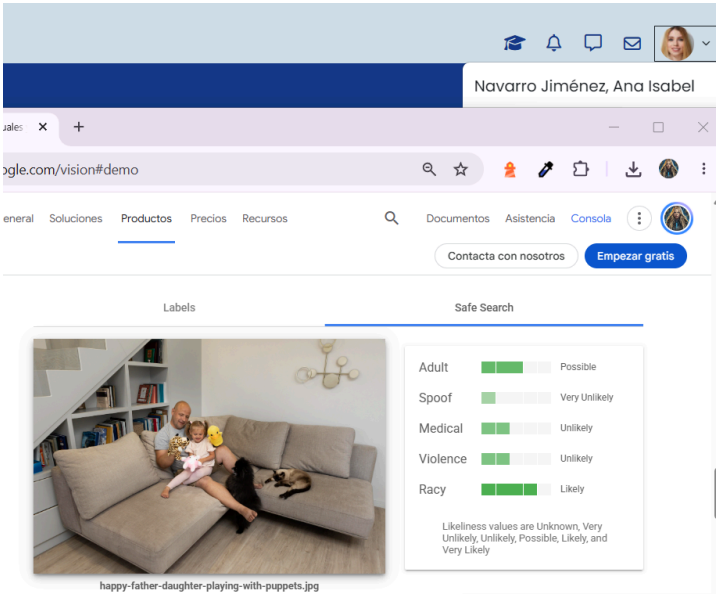
Sin embargo, al examinar la profundidad de los datos, se notan las diferencias. AWS desglosa a cada sujeto de forma individualizada: diferencia entre hombres y mujeres, estima rangos de edad acertados (desde jóvenes de 9 a 15 años hasta personas de más de 60) y señala qué individuos concretos llevan gafas. Google, en cambio, mantiene su criterio de no ofrecer datos demográficos, omitiendo edades o géneros para centrarse en la orientación y giro de las cabezas. Además, Google devuelve una lista muy amplia de conceptos globales de la escena (como "amistad", "ropa", "diversión" o "gafas"), aunque los asigna a la imagen en su conjunto sin especificar a qué persona corresponden.

En limitaciones encontramos que a Google le falta esa capacidad individual que es importante para analizar grupos. Sin embargo, AWS muestra dudas al examinar ciertos rostros, por ejemplo en una de las caras más jóvenes duda sobre la sonrisa (otorgando un 68% de confianza).

En cuanto a los niveles de certeza, AWS proporciona métricas numéricas exactas para cada rasgo detectado en los seis individuos. Google emplea porcentajes elevados (entre el 87% y el 98%) para confirmar la detección de los rostros, pero recurre a su escala cualitativa para las emociones, asignando "Very Likely" casi siempre y un "Possible" en un caso donde la expresión no es tan evidente.

Imagen 3: Escena con múltiples objetos
Imagen de Magnific (Libre) | Imagen | Ha sido seleccionada para analizar una escena completa en la que aparece una niña jugando con su padre con marionetas, varias mascotas y muebles diferentes para probar la detección múltiple de entidades más allá del simple análisis facial.





Al analizar esta escena más compleja mediante la detección de etiquetas, las diferencias de enfoque entre Google y AWS se vuelven mucho más grandes y evidentes.

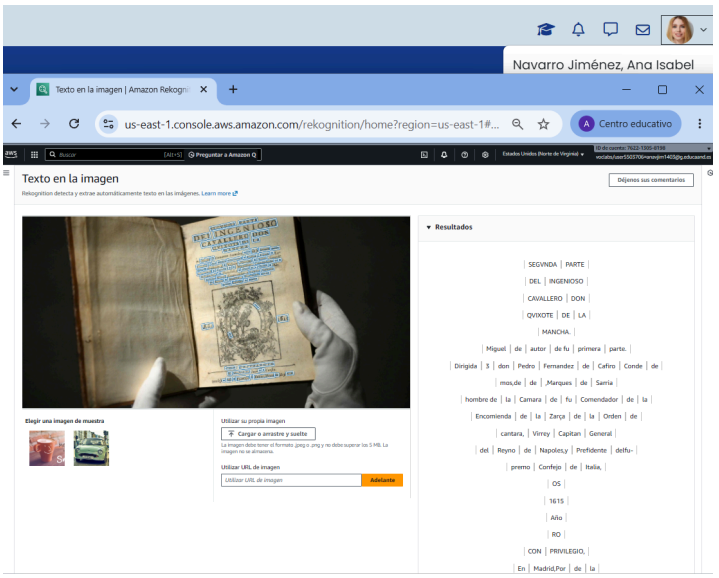
Por un lado, AWS revela un análisis muy detallado y correcto del entorno global, identificando con precisión la habitación como el salón y detectando tanto la presencia humana como los objetos con los que interactúan (marionetas etiquetadas como "Toy"). AWS demuestra además una gran capacidad para escanear el fondo, logrando detectar la escalera de la izquierda ("Staircase", 55.2%) y asumiendo que debajo hay una librería ("Bookcase", 55.1%).

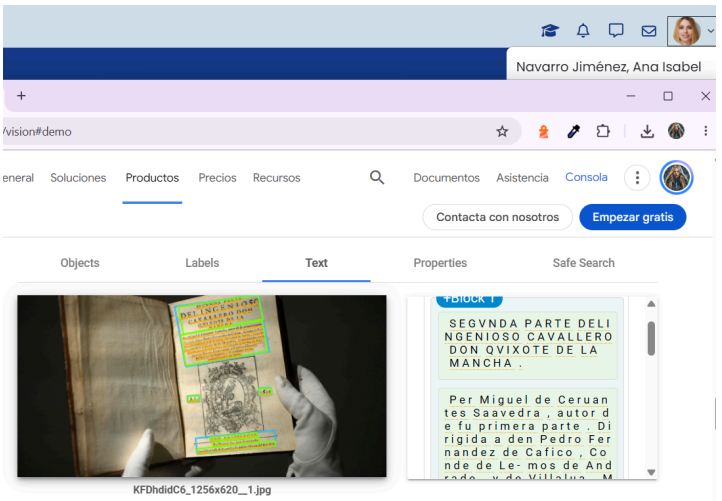
Por el contrario, Google Cloud Vision sufrió un error de lectura de datos ("Bad image data") que le impidió detectar rostros, sujetos específicos o los juguetes. Por lo que Google actuó se centró mas en la decoración de la habitación y acertó en la detección del sofá, los cojines, el suelo de madera y, afinando más que AWS en los pequeños detalles de decoración, detectó correctamente la lámpara de pared del fondo ("Lamp", 70%) y la maceta de la derecha ("Houseplant", 66%).

En cuanto a los errores, ambos tienen fallos garrafales. AWS, aunque ve a las personas, no especifica que hay una niña y su error más evidente es de clasificación, confunde al ubicar a las mascotas y etiqueta a un gato claramente visible como si fuera un perro. En cuanto a Google no detecta humanos ni animales ni marionetas. Pero lo más sorprendente es el gran error de contexto que comete su filtro de seguridad, evaluando la escena familiar como picante o sugerente ("Racy") con una probabilidad alta ("Likely"), incluso contenido para adultos como posible ("Possible").

Si observamos los valores de confianza y las diferencias relevantes, AWS se muestra muy tajante, asignando un 97.1% de seguridad a su error de confundir al gato con un perro y un altísimo 96.6% a los juguetes. Google, por su parte, asigna confianzas casi absolutas a elementos estructurales como el sofá (98%).

Imagen 4: Imagen con texto
Imagen de Daniel Leal/AFP de la redacción de él Clarín | Imagen | He seleccionada una imagen en la que aparece una de las versiones más antiguas que se conservan del libro de Cervantes *Don Quijote de La Mancha* para analizar cómo se comportan los modelos ante el reto de la ortografía y tipografía de otro siglo.





Al analizar una imagen centrada puramente en la extracción de texto con tipografía antigua, las diferencias de precisión y estructuración entre Google Cloud Vision y AWS Rekognition son muy notables.

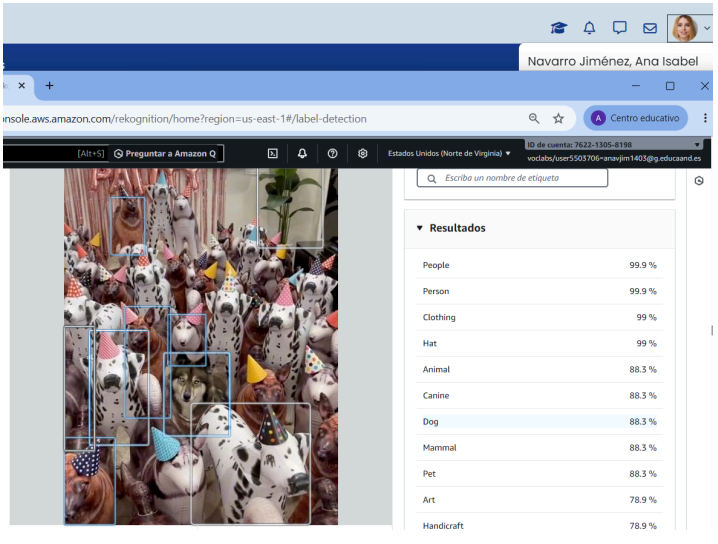
Ambas plataformas logran identificar que se trata de un documento y extraen el bloque de texto casi en su totalidad. Sin embargo tienen enfoques muy distintos, Google agrupa la información de forma semántica devolviendo un párrafo bastante fiel a la estructura original, mientras que AWS procesa el texto línea por línea y palabra por palabra, lo que es útil para la ubicación espacial pero rompe la fluidez del texto. A pesar de esto, las superan muy bien la ortografía peculiar de la época en las letras mayúsculas grandes, leyendo a la perfección el título "SEGVNDA PARTE" y "QVIXOTE" (respetando el uso de la 'V' en lugar de la 'U') y logrando identificar correctamente caracteres especiales antiguos como la ce cedilla en la palabra "Zarça".

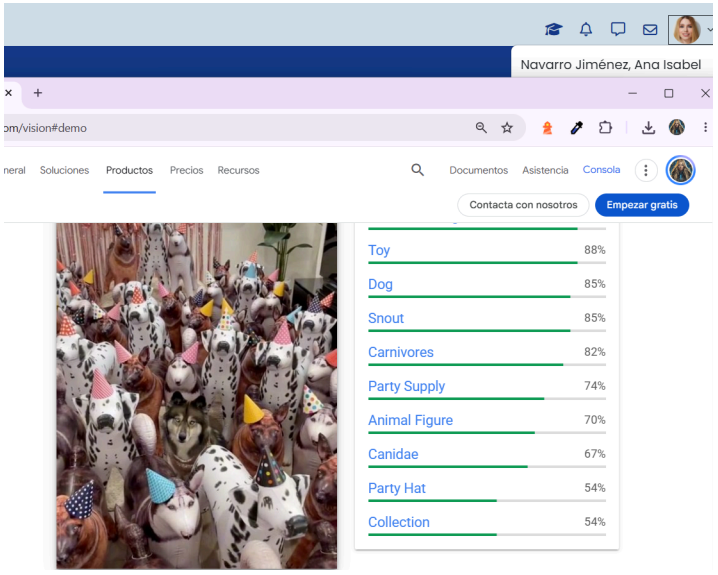
En cuanto a los errores el mayor problema para ambas es la llamada 's' larga ('ſ') de la tipografía antigua, que se escribía de forma muy parecida a una 'f'. Por culpa de esto, en la palabra original "Caftro" (Castro), Google lee "Cafico" y AWS lee "Cafiro"; y en "vendese", AWS se confunde doblemente leyendo "pendefe", mientras que Google se acerca más al leer "vendefe".

Por otro lado, encontramos fallos específicos en cada plataforma. Google comete un error de espaciado al principio uniendo dos palabras ("DELINGENIOSO"), que AWS sí separa correctamente ("DEL INGENIOSO"). Sin embargo, Google demuestra estar mejor entrenado en caracteres hispanos al detectar perfectamente la letra ñ "Peñafiel", mientras que AWS devuelve "Penafiel". Además, el mayor punto débil de AWS en esta prueba son las "alucinaciones", intenta leer manchas o adornos del papel antiguo como si fueran texto, inventándose caracteres sin sentido como "OS", "RO", "P.E" y "v" al final del análisis, e incluso confunde la letra "a" con un número, leyendo "Dirigida 3 don Pedro".

Si observamos los valores de confianza, AWS se muestra sumamente seguro (97% - 98%) al leer las mayúsculas grandes del título, pero su porcentaje cae drásticamente por debajo del 50% en las zonas donde la tipografía es pequeña, junta o donde comete errores graves como "Gonernador" o "Saanedra". Google, por su parte, mantiene un nivel de confianza más estable en torno al 80% para todo el bloque continuo de texto.

Imagen 5: Imagen de especial dificultad
Imagen de un reto viral de internet (Libre) | Imagen | He optado por utilizar una imagen de un reto viral cómico que consiste en localizar a un perro escondido entre decenas de perros de peluche y figuras, seleccionada para poner a prueba la capacidad de las IAs para diferenciar animales reales de representaciones artificiales (juguetes) en un entorno de alta confusión visual.





Al enfrentar a ambos modelos a una imagen diseñada específicamente para crear confusión, los resultados demuestran que ninguna IA es infalible ante las trampas visuales, reaccionando de maneras muy distintas.

En cuanto a la información obtenida, Google asume un enfoque global y conceptual, identificando la escena como algo lúdico y lleno de objetos inanimados ("Toy", "Party Supply", "Animal Figure"). Por su parte, AWS hace un análisis mucho más desordenado y caótico intentando clasificar individualmente cada forma que encuentra, lo que le lleva a devolver una lista que mezcla perros, ropa ("Clothing", "Hat"), arte ("Art") y hasta la presencia de humanos.

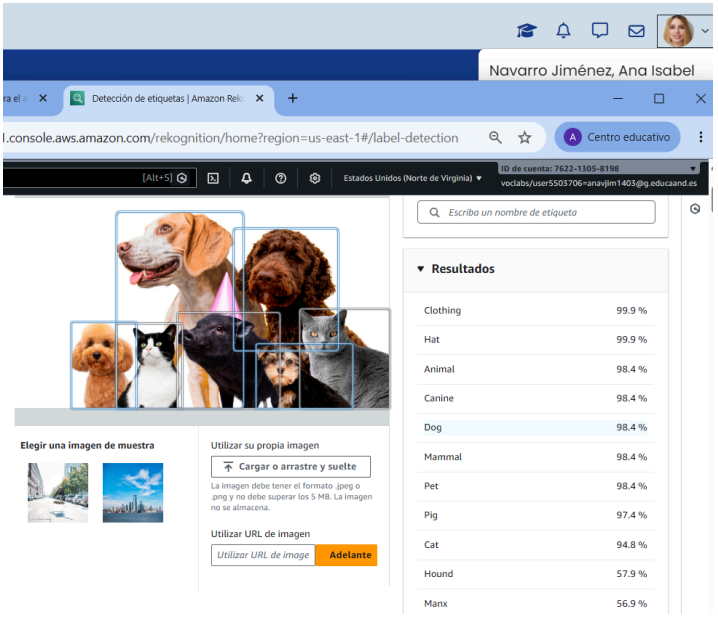
Si analizamos las detecciones correctas, a pesar del camuflaje ambas IAs logran identificar la temática canina y los objetos artificiales. Google etiqueta correctamente "Dog" y "Snout" (hocico), y afina bastante al detectar que la imagen está llena de peluches y juguetes ("Toy", "Stuffed toy"). AWS también detecta "Dog", situando múltiples cajas delimitadoras sobre diferentes perros de peluche de la imagen, y acierta al identificar que hay objetos hechos por el hombre ("Handicraft").

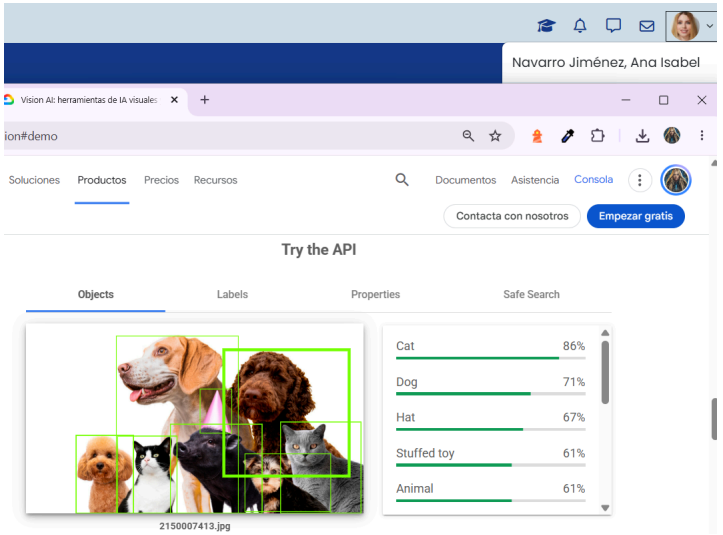
En cuanto a los errores, ninguna de las dos IAs logra aislar con éxito al único perro real descartando a los demás. Esta confusión lleva a los modelos al límite y provoca alucinaciones (falsos positivos). AWS, intenta buscar formas conocidas donde no las hay, alucina detectando un hombre adulto ("Adult", "Man") en la parte inferior izquierda de la imagen con un 75.5% de seguridad, e incluso etiqueta un canguro ("Kangaroo", 65.4%) en la parte inferior derecha, llegando a detectar motivos navideños ("Christmas").

Si observamos los valores de confianza, AWS mantiene un patrón errático. Le da una confianza extrema y casi absoluta (99.9%) a su alucinación de que hay ropa y personas, pero le otorga una confianza mucho menor a los perros (entre el 60% y el 88%). Google es más consistente y lógico, otorgando confianzas altas y similares tanto a los perros como a los juguetes.

Por último, una de las diferencias más relevantes la encontramos en el filtro de seguridad (SafeSearch). Mientras que AWS intenta forzar la detección de objetos aislados y acaba alucinando canguros y personas, Google maneja mucho mejor la naturaleza engañosa y aunque no diferencia al perro real, su filtro de seguridad marca la etiqueta "Spoof" (engaño/parodia) como "Possible". Esto demuestra que el modelo de Google intuye que la imagen tiene truco.

Imagen 6: Caso relacionado con su proyecto
Imagen de Magnific (Libre) | Imagen | Imágenes de diferentes animales para comprobar la capacidad de diferenciar entre varios tipos de gatos, perros u otros de cada modelo y con qué precisión





Para un proyecto cuyo objetivo es monitorizar mascotas, he decido usar esta imagen para analizar cómo ambas plataformas gestionaría la presencia de múltiples especies.

Ambas plataformas logran identificar el concepto principal de animales. Las dos devuelven etiquetas genéricas como "Dog" (perro), "Animal" y "Carnivores" o "Canine". Sin embargo, AWS presenta una ventaja fundamental para nuestro proyecto, devuelve un bloque detallado para casi todas sus etiquetas, lo que significa que no solo dice "hay un perro", sino que da las coordenadas exactas de dónde se encuentra cada uno de los perros, gatos y cerdos.

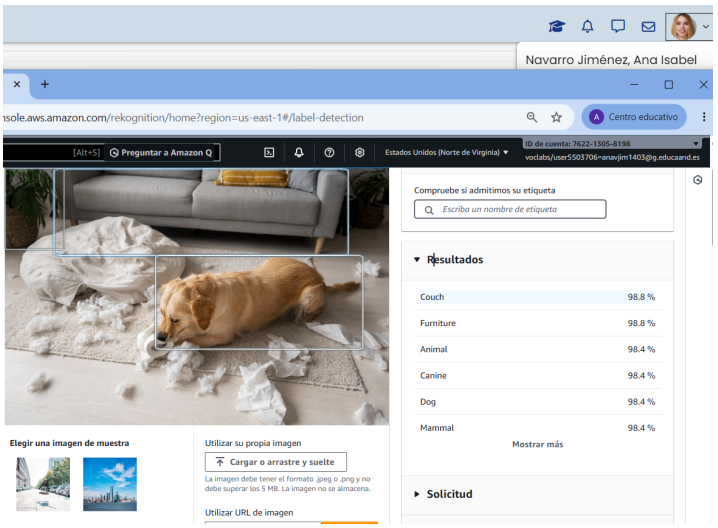
Si nos fijamos en las detecciones correctas, el nivel de acierto de AWS es notable para la separación de especies, detecta a los perros (98.4%), pero además aísla correctamente al cerdo ("Pig", 97.4%) y a los gatos ("Cat", 94.8%). Google también detecta a los perros (99.5%) y logra localizar a los gatos (85.8% y 60.6%), pero falla al identificar al cerdo, generalizándolo como "Animal" (60.9%).

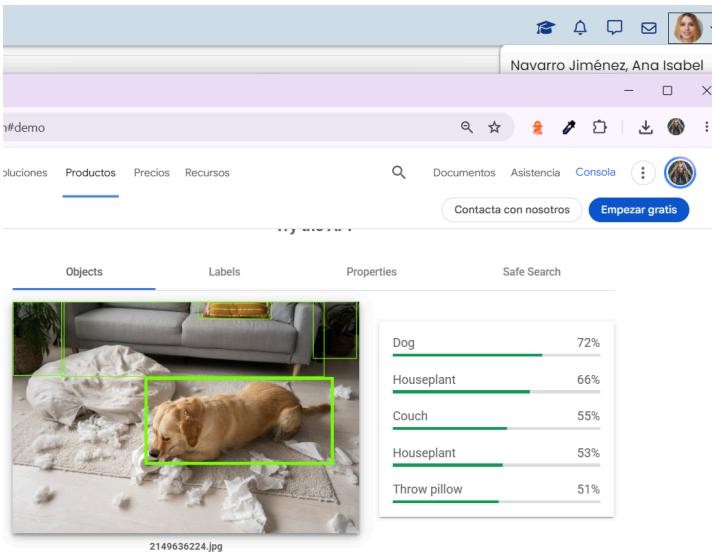
En cuanto a los errores, Google etiqueta un perro de juguete ("Toy dog", 85%). AWS comete una alucinación y asume que hay personas ("Person", "Face") e incluso fotografía ("Photography", "Portrait") rondando el 56% de confianza. Además, AWS intenta adivinar razas de manera arriesgada, sugiriendo "Hound" (sabueso) y "Manx" (una raza de gato sin cola) con baja confianza.

En los valores de confianza, AWS es muy contundente con las especies que ve claramente (perros, cerdos y gatos superan el 94%), y su seguridad se dispara (99.9%) con el gorro que tiene el cerdo. Google es muy preciso con el perro principal (99.5%), pero duda mucho más (entre el 54% y el 71%) al localizar el resto de objetos y animales.

La diferencia relevante entre los dos servicios y su impacto en nuestro proyecto es clara. AWS demuestra ser mucho más robusto para contar e identificar especies distintas en una misma escena, dando las coordenadas exactas de dónde está el cerdo, dónde el gato y dónde el perro. Google, aunque detecta la esencia de la imagen, omite especies minoritarias (el cerdo) y se confunde inventando juguetes. Para un sistema de vigilancia doméstica, AWS ofrece una base mucho más sólida para aislar al "gato" del "perro" antes de intentar identificarlos por su nombre.

Imagen 7: Extra interesante de ser comentada para el proyecto
Imagen de Magnific (Libre) | Imagen | Pese a que no se pida en la tarea he considerado importante mencionar esta imagen ya que es una de las condiciones más necesarias para que sea capaz de analizar la IA para nuestro proyecto de imagenes de cámara de mascotas. He seleccionado un perro comportándose mal rompiendo un rollo de papel para ver hasta dónde puede llegar la detección de los modelos en comportamientos animales





Al analizar esta imagen de mal comportamiento, ambas plataformas demuestran una gran capacidad para detectar a los sujetos principales, pero se quedan a medias a la hora de interpretar la acción.En cuanto a la información obtenida, tanto Google como AWS identifican rápidamente el entorno doméstico, al perro y el mobiliario de fondo. Además, las dos detectan sin problemas la presencia de un "Dog", "Mammal", "Carnivores" y "Pet".

Las detecciones correctas son sólidas en cuanto a los elementos físicos. Google afina bastante detectando que se trata de un cachorro ("Puppy", 80%) y AWS también lo incluye en su lista ("Puppy", 55%). AWS detecta correctamente la presencia de plantas ("Plant", 61%) y del papel ("Paper", 70%), elementos clave en la escena. Google, por su parte, detecta artículos para mascotas ("Pet Supply", "Dog Supply").

Sin embargo, hay muchísima información relevante no detectada. El gran problema de ambos modelos es que son estáticos, detectan los superficiales (perro, papel, sofá), pero no la acción. Ninguna de las IAs devuelve etiquetas que sugieran "mal comportamiento", "travesura", "mordida" o "desorden". El contexto de la acción destructiva pasa completamente desapercibido para ambos sistemas.

Los posibles errores en esta imagen son más de interpretación material que de alucinaciones graves. AWS intenta clasificar el rastro de papel roto y sugiere débilmente que podría ser una toalla ("Towel", 55%). Google, al intentar categorizar el tipo de perro, se aventura a decir que podría ser un perro ("Retriever") o un perro de caza ("Gun dog") con un 50% de probabilidad, lo cual sería arriesgado para nuestro modelo.

Si miramos los valores de confianza, AWS es muy rotundo con los sujetos principales (da un 98.8% al sofá y un 98.4% al perro), pero duda mucho con los detalles como la toalla o la planta. Google reparte valores dando su mayor confianza al perro (99.4%) y a los carnívoros (88%), pero curiosamente le da un valor de confianza bajo al sofá ("Couch", 68%) comparado con AWS.

La diferencia relevante entre los dos servicios es cómo trocean la escena. AWS sí logra identificar el material que está rompiendo el perro al detectar "Paper" (Papel), lo cual es crucial para entender la escena, aunque no logre unir la acción de romper. Google se centra más en categorizar la morfología del perro (hocico, pelaje, raza) y los enseres para mascotas, pero ignora por completo el papel higiénico destrozado.

C) Análisis de la respuesta JSON
Para el análisis de todas las imágenes anteriores, he considerado necesario examinar las respuestas en formato JSON de todas las imágenes. Aunque la interfaz visual básica de cada servicio aporta una primera impresión útil, considero que las verdaderas diferencias técnicas y estructurales entre ambos modelos solo se aprecian al inspeccionar directamente la información de cada JSON.

Por lo que pese a que he utilizado los JSON de todas en el apartado anterior, para comentar y para responder a este apartado con más detalle, tomaré como referencia la **Imagen 6 (Múltiples animales)**, en la que aparecen perros, gatos y un cerdo y podemos visualizar sus diferencias en la siguiente tabla:

Criterio	AWS Rekognition	Google Cloud Vision
Enfoque estructural	Unificado y centrado en la etiqueta: Agrupa la semántica y la ubicación espacial en un único bloque estructurado	Modular y fragmentado: Separa por completo la comprensión conceptual de la ubicación física en diferentes arrays..
Estructura principal en el JSON	Array raíz Labels, que contiene objetos con la información del concepto y sus instancias.	Múltiples arrays de primer nivel: labelAnnotations (conceptos) y localizedObjectAnnotations (ubicaciones).
Formato del nivel de confianza	Porcentaje numérico sobre 100 (campo Confidence, ej. 98.455...).	Valor decimal entre 0 y 1 (campos score o Confidence, ej. 0.995...).
Jerarquía	Incluye arrays integrados de contexto como Parents y Categories (ej. perro → canino).	Devuelve etiquetas descriptivas globales sin una jerarquía de parentesco directa en su estructura básica.
Ubicación espacial	Utiliza el bloque Instances dentro de la etiqueta. Si hay varios animales iguales, los agrupa bajo la misma etiqueta con múltiples cajas.	Utiliza localizedObjectAnnotations con un polígono de cuatro vértices (normalizedVertices).
Consistencia de datos	Alta cohesión: la etiqueta y su posición física van siempre de la mano en el mismo nodo.	Puede haber desajustes ocasionales (por ejemplo, detectar un concepto conceptualmente sin asignarle coordenadas de objeto).

Explicación de extracción y utilización automática mediante programación
Para integrar esta información en mi sistema de monitorización mediante un script en Python (tal y como exige el diseño de la aplicación), el proceso se plantearía de la siguiente manera:

- Extracción de datos: Si opto por AWS Rekognition, mi código recorrerá de forma directa el array unificado data["Labels"] filtrando por label["Name"] == "Dog" o "Cat". Si utilizo Google Cloud Vision, el proceso requerirá consultar primero data["labelAnnotations"] para la semántica y, posteriormente, buscar de forma independiente en data["localizedObjectAnnotations"] para obtener las coordenadas.

- Recorte inteligente: Una vez localizada la etiqueta y sus coordenadas (mediante los valores normalizados de Top, Height, etc., en AWS, o los vértices en Google), mi programa multiplicará estas proporciones por la resolución real de la cámara y utilizará OpenCV para recortar exactamente el recuadro del animal.

- Identificación personalizada: Este recorte se enviará a mi propio modelo de IA entrenado para resolver la identificación unívoca ("¿Es Toby o es Kali?").

- Sistema de alertas y Geofencing: Al disponer de las coordenadas, el sistema las comparará en tiempo real con las "zonas prohibidas" dibujadas por el usuario, disparando una notificación push si se encuentra en dicha zona.

D) Conclusiones

A partir de las pruebas que he realizado en las distintas actividades, puedo decir que ambos servicios ofrecen un nivel excelente de precisión general en la detección de objetos y rostros, pero con diferentes políticas.

Amazon Rekognition destaca por ofrecer un desglose exhaustivo, cuantitativo y estructurado de manera unificada. Es sumamente preciso en el análisis biométrico individualizado de los rostros y agrupa de forma muy limpia los objetos. Su principal punto débil, bajo mi punto de vista, radica en cierta rigidez a la hora de interpretar contextos generales complejos cuando no encajan exactamente en sus etiquetas predefinidas.

Google Cloud Vision destaca por su enorme potencia en la comprensión contextual y la lectura global de la escena. Su arquitectura separa el posicionamiento espacial y compensa la ausencia inicial de datos demográficos directos con una capacidad alta para deducir información del entorno (ropa, fondo, objetos secundarios). Sin embargo, su estructura fragmentada la hace ligeramente menos directa para tareas finas de sujetos múltiples.

Por lo que todo esto me ayuda a determinar que en cuanto al proyecto en concreto de detección de mascotas por cámara mediante inteligencia artificial, considero que Amazon Rekognition resultaría más adecuado. Ya que posee un procesamiento de agrupaciones más eficiente y es mucho más sólido en el filtrado biométrico y de rostros muy útil en el proyecto para el filtrado inicial de los rostros asegurando así la política de privacidad del usuario.

Por lo que la verdadera utilidad de este servicio como Amazon Rekognition en el proyecto se limitaría a una primera fase de filtrado previo y posicionamiento espacial. Ya que nos permitiría recortar la imagen donde se encuentra el animal para enviarla posteriormente a nuestro propio modelo personalizado (entrenado previamente), que es el que realmente aportará la inteligencia específica que exige el proyecto.