UNIÓN EUROPEA
Fondo Social Europeo

Tarea online PIA02.

1.- Descripción de la tarea.

2.- Información de interés.

3.- Evaluación de la tarea.

Licencia: licencia propietaria

1.- Descripción de la tarea.

Caso práctico



Elaboración Propia, Generada con IA. *Estudio de datos de población activa.*

Carla, como nueva integrante del departamento de informática de una gran empresa de marketing, ha recibido el encargo de explorar datos sobre población activa en España. Este análisis servirá de base para futuras campañas de marketing para centros de formación laboral.

El trabajo que tiene por delante es desafiante, ya que los datos que deberá analizar son muy amplios y provienen de diversas fuentes, lo que implica manejar grandes volúmenes de dados y hacer frente a problemas relacionados con la calidad y la integración de los datos. Entre los obstáculos que Carla probablemente encontrará están la variedad de formatos, la necesidad de limpiar registros erróneos o incompletos, y la integración de datos de diferentes orígenes.

El **lenguaje R** le ofrece una gran cantidad de herramientas que le facilitarán el proceso. Carla podrá utilizar R no solo para

procesar los datos de manera eficiente, sino también para limpiar y transformar la información, realizar análisis estadísticos y crear visualizaciones claras y atractivas que destaquen patrones y tendencias. R le permitirá automatizar tareas repetitivas, facilitando que el análisis sea reproducible y escalable, lo que resultará fundamental en un proyecto de esta magnitud.

Gracias a la versatilidad de R, Carla estará en una posición ideal para superar los retos de manejar una gran cantidad de datos.

Presentación de la Tarea

El Instituto Nacional de



Estadística (INE) pone a disposición de la ciudadanía una gran cantidad de información sobre aspectos demográficos, económicos y sociales de España. Estos datos constituyen una fuente de información de gran valor para conocer la realidad de nuestro entorno, identificar tendencias y apoyar la toma de decisiones.

Sin embargo, los datos no siempre se encuentran preparados para su análisis. Habitualmente es necesario descargarlos de distintas fuentes, comprender su estructura, corregir formatos, seleccionar la información relevante y combinar diferentes conjuntos de datos.

En esta tarea asumirá el papel de un analista de datos al que se le ha encargado elaborar un estudio sobre la situación socioeconómica de las provincias españolas durante el año 2023, prestando especial atención a las diferencias entre hombres y mujeres.

Para ello, utilizará el lenguaje de programación R y el entorno RStudio, trabajando con información oficial del INE sobre población, mercado laboral y renta.

El proyecto se desarrollará progresivamente, desde la obtención y preparación de los datos hasta su integración, análisis y representación gráfica.

Objetivos

Al finalizar la tarea deberá ser capaz de:

- Localizar, descargar e interpretar conjuntos de datos procedentes de fuentes oficiales.
- Importar archivos CSV y explorar su estructura mediante R.
- Limpiar, transformar y preparar datos para su análisis.
- Combinar distintos dataframes mediante campos comunes.
- Utilizar funciones, estructuras de control y operaciones sobre vectores.
- Obtener indicadores y resúmenes estadísticos.
- Representar gráficamente información utilizando R.
- Interpretar los resultados y reconocer las limitaciones de los datos utilizados.

Fuentes de datos

Para realizar el proyecto se utilizarán tres conjuntos de datos del INE.

1. Población: Población por provincia, sexo y año
2. Mercado laboral:Tasas de actividad, paro y empleo por provincia y sexo
3. Renta: Renta neta media por persona y provincia

También encontrará los tres archivos CSV, ya descargados, en el apartado Información de interés de la tarea. Pero es de interés que explore el portal del INE ya que es una fuente de datos muy relevante.

El año de referencia será 2023.

Directorio de Trabajo

Para facilitar su trabajo puede crear el script en un directorio con los ficheros de datos (siguiendo las indicaciones sobre la entrega en la "Información de Interés") y utilizar el siguiente fragmento de código para establecer el directorio de trabajo de forma dinámica según la ubicación del propio script, dando portabilidad a su script.

```
# En RStudio, si el script esta guardado y activo, usar su carpeta.

if (requireNamespace("rstudioapi", quietly = TRUE) && rstudioapi::isAvailable()) {

    ruta <- rstudioapi::getActiveDocumentContext()$path

    if (nzchar(ruta)) setwd(dirname(ruta))

}
```

¿Qué te pedimos que hagas?

Actividad 1. Preparación del entorno y exploración de los datos (1 punto)

Instale R y RStudio, si todavía no dispone de ellos, y prepare un directorio de trabajo para el proyecto.

Explore el portal del INE y el mecanismos para seleccionar los datos, su estructura y formato.

Descargue los tres conjuntos de datos desde el portal del INE y realice las siguientes operaciones:

- Cargue los tres archivos CSV en R, utilizando las instrucciones y parámetros adecuados.
- Visualice los primeros registros de cada dataframe.
- Identifique el número de filas y columnas, los nombres de los atributos y sus tipos de datos.
- Examine los distintos valores que presentan las variables utilizadas para identificar territorios, periodos, sexos e indicadores. El explorador de entorno de R-Studio le resultará de utilidad.
- Identifique los posibles problemas que dificultan el análisis directo de los datos.
- Crea una función llamada ***estudiar_conjunto*** que visualice los datos del conjunto.

Entrega:

- Para esta tarea se elaborará una **memoria** con los pasos seguidos, los problemas encontrados, las soluciones adoptadas y el análisis propuesto para cada apartado, así como capturas que demuestren la autoría.
- Además se adjuntará un **script R** con el código y comentarios, identificando claramente cada apartado. Debe permitir su ejecución sin preparativos extra.
- Para este apartado el script contendrá la carga de los datos, el diseño de la función y su invocación para cada conjunto de datos.

Aquí un ejemplo orientativo del resultado de esta función para el conjunto de datos de población.

```
> estudiar_conjunto("Conjunto Poblacion:",poblacion_original)
[1] "Conjunto Poblacion:"
[1] "Registros: 1080     ---- N. Atributos: 6"
[1] "Atributos:"
[1] "Total Nacional"                  "Comunidades y Ciudades Autónomas" "Provincias"
[4] "Sexo"                            "Periodo"                          "Total"
  Total Nacional Comunidades y Ciudades Autónomas Provincias    Sexo Periodo      Tota
1 Total Nacional                                              Total    2025 49.128.29
2 Total Nacional                                              Total    2024 48.619.69
3 Total Nacional                                              Total    2023 48.085.36
4 Total Nacional                                              Total    2022 47.486.72
5 Total Nacional                                              Total    2021 47.400.79
6 Total Nacional                                            Hombres    2025 24.090.36
```

Actividad 2. Limpieza y preparación de los datos (1,5 puntos)

Los conjuntos de datos originales contienen información correspondiente a diferentes periodos, territorios y categorías. Antes de combinarlos es necesario preparar cada dataframe.

Antes de afrontar esta tarea le vendrá bien diseñar funciones auxiliares que le permitan:

- Pasar los cuantitativos de carácter a numérico.
- Quitar el código numérico que precede a los nombres de comunidades y provincias, si es necesario.

Realice las siguientes operaciones sobre cada conjunto de datos.

2.A. Datos de Población

- Seleccione los registros correspondientes a 2023.
- Conserve únicamente los registros provinciales y los correspondientes a hombres y mujeres. Prescinda de agregados.
- Elimine las columnas que no resulten necesarias.
- Renombre las variables para facilitar su utilización.

```
> print(head(poblacion));
  comunidad provincia anio    sexo poblacion
1 Andalucía   Almería 2023 Hombres     385696
2 Andalucía   Almería 2023 Mujeres     367668
3 Andalucía     Cádiz 2023 Hombres     618291
4 Andalucía     Cádiz 2023 Mujeres     636575
5 Andalucía   Córdoba 2023 Hombres     379239
6 Andalucía   Córdoba 2023 Mujeres     395763
```

2.B. Datos del Mercado Laboral

- Seleccione los cuatro trimestres de 2023.
- Conserve las tasas de actividad, paro y empleo de hombres y mujeres.
- Elimine los registros agregados nacionales y autonómicos.
- Convierta los indicadores a valores numéricos.
- Prepare los datos, en la siguiente actividad calcularemos las tasas medias anuales.

```
> print(head(e,8))
         Sexo  Provincias                        Tasas Periodo Total provincia valor
15887 Hombres 02 Albacete           Tasa de actividad  2023T4 63,37  Albacete 63.37
15888 Hombres 02 Albacete           Tasa de actividad  2023T3 66,31  Albacete 66.31
15889 Hombres 02 Albacete           Tasa de actividad  2023T2 67,78  Albacete 67.78
15890 Hombres 02 Albacete           Tasa de actividad  2023T1 66,62  Albacete 66.62
15985 Hombres 02 Albacete Tasa de paro de la población  2023T4  9,57  Albacete  9.57
15986 Hombres 02 Albacete Tasa de paro de la población  2023T3  8,04  Albacete  8.04
15987 Hombres 02 Albacete Tasa de paro de la población  2023T2 10,64  Albacete 10.64
15988 Hombres 02 Albacete Tasa de paro de la población  2023T1 11,38  Albacete 11.38
```

2.C. Datos de Renta

- Seleccione los registros correspondientes a 2023.

- Conserve la renta neta media por persona de cada provincia.
- Elimine las variables innecesarias y transforme los valores al tipo numérico.
- Finalmente, normalice las denominaciones de las provincias para que puedan utilizarse como claves de unión.

```
> print(head(renta))
  provincia renta_media
1   Almería       11543
2     Cádiz       12335
3   Córdoba       12386
4   Granada       12709
5    Huelva       12008
6      Jaén       11847
```

Como entrega, explique en la memoria las principales transformaciones realizadas y aporte el código correspondiente bien identificado en el script. Incluya alguna comprobación que permita verificar los resultados obtenidos.

Actividad 3. Cálculo de indicadores laborales anuales (1,5 punto)

La Encuesta de Población Activa proporciona información trimestral. Para nuestro estudio necesitamos disponer de un único valor anual por provincia, sexo e indicador.

Calcule las tasas medias para 2023 a partir de sus cuatro trimestres. Las tasas anuales se calcularán como la media aritmética de los cuatro trimestres de 2023. Realmente no se calcula por media aritmética de los cuatro trimestres, pero lo haremos así para simplificar el problema. Compruebe que se han utilizado los cuatro trimestres para calcular cada indicador y que el resultado contiene un único registro por provincia y sexo.

El dataframe resultado tendrá las siguientes columnas:

- Provincia.
- Sexo.
- Tasa media anual de actividad.
- Tasa media anual de paro.
- Tasa media anual de empleo.

```
> print(head(epa))
         provincia    sexo tasa_actividad tasa_paro tasa_empleo
1          Albacete Hombres        66.0200    9.9075     59.4750
2          Albacete Mujeres        51.0725   14.5650     43.6250
3 Alicante/Alacant Hombres        63.6925   11.3575     56.4650
4 Alicante/Alacant Mujeres        53.1625   15.7275     44.8000
5           Almería Hombres        68.2875   15.0375     58.0000
6           Almería Mujeres        54.7400   17.2575     45.3275
```

Como entrega, explique en la memoria las principales transformaciones realizadas y aporte el código correspondiente bien identificado en el script. Incluya alguna comprobación que permita verificar los resultados obtenidos.

Actividad 4. Integración de los conjuntos de datos (2 puntos)

Una vez preparados los tres conjuntos, deberá combinarlos en un único dataframe que reúna la información demográfica, laboral y económica de las provincias españolas.

El dataframe final tendrá las siguientes columnas:

- comunidad: Comunidad autónoma
- provincia: Provincia
- anio : Año de referencia
- sexo: Hombre o Mujer
- poblacion: Población del sexo correspondiente
- tasa_actividad: Tasa media anual de actividad
- tasa_paro: Tasa media anual de paro
- tasa_empleo: Tasa media anual de empleo
- renta_media: Renta neta media por persona de la provincia

Utilice la función merge() para realizar las uniones, seleccionando correctamente los campos comunes.

Compruebe que:

- El dataframe contiene los 104 registros esperados.
- No existen registros duplicados para una misma provincia y sexo.
- Los valores de las variables son del tipo adecuado.
- No se han perdido provincias durante las uniones.
- La renta media de cada provincia aparece en los dos registros correspondientes a hombres y mujeres.
- Ordene el dataframe por comunidad autónoma, provincia y sexo.

```
> print(head(datos))
              comunidad        provincia anio    sexo poblacion tasa_actividad tasa_paro tasa_empleo renta_medi
1 Castilla - La Mancha         Albacete 2023 Hombres    194012        66.0200     9.9075      59.4750       1305
2 Castilla - La Mancha         Albacete 2023 Mujeres    193517        51.0725    14.5650      43.6250       1305
3 Comunitat Valenciana Alicante/Alacant 2023 Hombres    966477        63.6925    11.3575      56.4650       1231
4 Comunitat Valenciana Alicante/Alacant 2023 Mujeres    988791        53.1625    15.7275      44.8000       1231
5              Andalucía          Almería 2023 Hombres    385696        68.2875    15.0375      58.0000       1154
6              Andalucía          Almería 2023 Mujeres    367668        54.7400    17.2575      45.3275       1154
```

Como entrega, aporte el código, mostrando el dataframe final. Explique en la memoria las claves utilizadas en cada unión. Exporte también el resultado a un archivo CSV.

Actividad 5. Desarrollo de una función de consulta (1 punto)

Diseñe una función denominada consultar_provincia() que reciba como parámetros el dataframe integrado y el nombre de una provincia.

La función deberá:

- Comprobar que los parámetros recibidos son válidos.
- Verificar que la provincia existe en el dataframe.
- Devolver los dos registros correspondientes a hombres y mujeres.
- Mostrar un mensaje de error informativo si la provincia no existe.

Por ejemplo:

```
> consultar_provincia(datos, 'Granada')
  comunidad provincia anio    sexo poblacion tasa_actividad tasa_paro tasa_empleo renta_media
1 Andalucía   Granada 2023 Hombres    460537        64.1575   17.1850     53.1350       12709
2 Andalucía   Granada 2023 Mujeres    473535        52.9225   24.3675     40.0175       12709
> consultar_provincia(datos, 'Graná')
Error in consultar_provincia(datos, "Graná") :
  Provincia no encontrada: Graná
```

Como entrega, aporte la función comentada, explicando su funcionamiento y mostrando ejemplos de ejecución correcta e incorrecta.

Actividad 6. Análisis estadístico de los datos (3 puntos)

Utilizando el dataframe integrado, realice las siguientes consultas:

- Identifique las cinco provincias con mayor y menor tasa de paro femenina.
- Determine las provincias con mayores diferencias entre las tasas de paro masculina y femenina.
- Calcule la tasa media de paro de hombres y mujeres en las provincias andaluzas.
- Identifique las cinco provincias con mayor renta media por persona.
- Determine si las provincias con mayor renta presentan también menores tasas de paro. Investigue con que indicador podríamos relacionar estas dos magnitudes. (Tip: Correlación entre datos)
- Para cada consulta, muestre los resultados obtenidos y explique brevemente las instrucciones utilizadas.

En esta última actividad, no será suficiente con mostrar los datos: deberá verificar los resultados y realizar una interpretación razonada de los mismos.

NOTA IMPORTANTE

Es necesario entregar una memoria que contendrá:

- **Una captura del código para cada apartado, legible y bien formado.**
- **Comentarios pedidos en cada apartado.**

Además se entregará un scritp preparado para ser ejecutado, junto con todos los ficheros necesarios.

Tenga en cuenta que se valorará la madurez de los contenidos demostrada en los comentarios aportados, no solo la consecución del apartado.