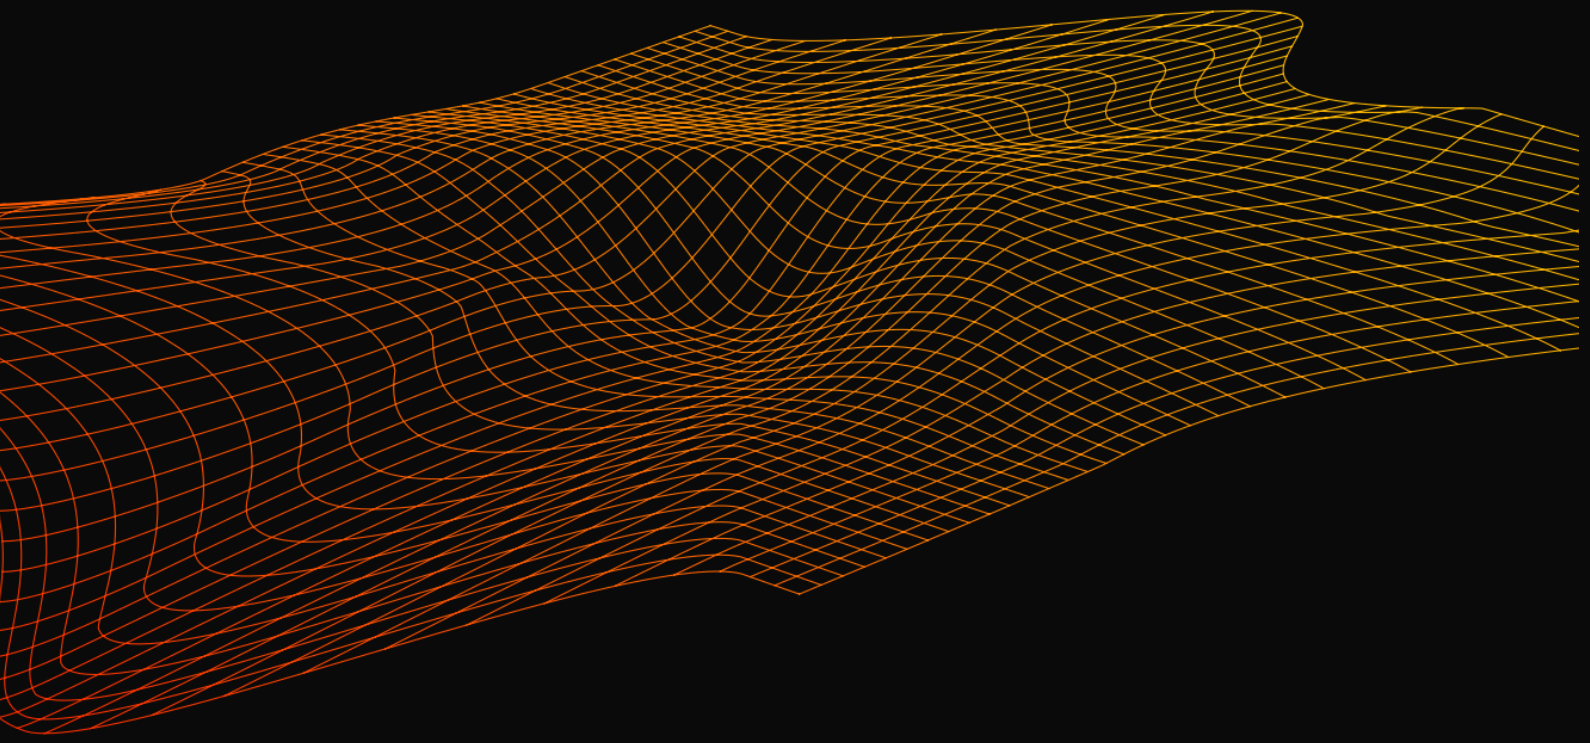
TAREA UNIDAD 1

Prediseño de un sistema Big Data

Sistemas de Big Data (SBD)



Inteligencia Artificial y Big Data

Ana Isabel Navarro Jiménez

ÍNDICE

1. Identificación de las 5V:.....3
2. Propuesta de arquitectura Big Data:.....4
3. Justificación de decisiones clave:.....6
Estrategia de escalado del clúster.....6
Propiedades ACID frente a BASE.....6
Subsistemas OLTP y OLAP.....6
Incorporación de un Data Warehouse.....6
4. Estrategias de procesamiento:.....7
Consulta en línea del estado de los envíos (transacciones diarias).....7
Alertas en tiempo real para incidencias (retrasos, averías, desvíos de ruta).....7
Informe semanal con métricas descriptivas (costes de combustible, puntualidad, utilización de la flota) con datos cerrados el domingo.....7
Modelo predictivo que anticipe retrasos probables en rutas según datos históricos.....7
5. Equilibrio CAP y SCV:.....7
6. Modelo predictivo:.....8

Caso práctico

Logística Nova XXI es una empresa de transporte y distribución que quiere explorar soluciones Big Data para modernizar su gestión. Sus características y necesidades son las siguientes:

- Hay distintas fuentes:
  - Externas a la empresa: datos abiertos de tráfico, climatología y precios de carburantes, actualizados varias veces por semana.
  - Internas a la empresa: telemetría en tiempo real de la flota de camiones (GPS, consumo, sensores de mantenimiento) y transacciones de envíos de clientes.
- La cantidad de datos actualmente es de aproximadamente 50 TB de datos históricos, con previsión de +15 TB/mes por incorporación de nuevos sensores.
- Requisitos de negocio:
  - Los clientes deben poder consultar en línea el estado de sus envíos (transacciones diarias).
  - El departamento de operaciones quiere alertas en tiempo real para incidencias (retrasos, averías, desvíos de ruta).
  - La dirección general necesita un informe semanal con métricas descriptivas (costes de combustible, puntualidad, utilización de la flota) con datos cerrados el domingo.
  - El área de planificación quiere un modelo predictivo que anticipe retrasos probables en rutas según datos históricos de tráfico y clima.



Camión de transporte en carretera (Dominio público)

1. Identificación de las 5V:

Explica cómo aparecen en el caso el Volumen (cantidad de datos), la Velocidad (frecuencia con que se generan), la Variedad (tipos y formatos), la Veracidad (calidad y fiabilidad de los datos) y el Valor (para qué sirven). Se espera que no solo se enumeren, sino que se ilustren con ejemplos concretos de la empresa.

Para determinar la viabilidad y la naturaleza del proyecto en la empresa Logística Nova XXI, es necesario analizar cómo se manifiestan las cinco dimensiones fundamentales del big data (las 5V) en el contexto de sus operaciones logísticas y de transporte:

1. Volumen: Se refiere a la magnitud de los datos almacenados y generados por la infraestructura de la empresa. En este caso, Logística Nova XXI gestiona actualmente un histórico de 50 TB de datos, a lo cual se suma un crecimiento estimado de +15 TB mensuales derivado de la incorporación continua de nuevos sensores en la flota. Esta volumetría excede por completo la capacidad de procesamiento y almacenamiento de los sistemas monomáquina tradicionales, haciendo obligatorio el uso de arquitecturas distribuidas.

2. Velocidad: Alude a la tasa de generación y procesamiento de los flujos de datos. En la compañía, esta dimensión se manifiesta en la telemetría en tiempo real transmitida por los camiones (datos de posicionamiento GPS, consumo de combustible y métricas de los sensores de mantenimiento), así como en la inmediatez requerida para la detección de incidencias operativas.

3. Variedad: Representa la diversidad en los tipos y formatos de los datos estructurados, semiestructurados y no estructurados. Logística Nova XXI integra fuentes heterogéneas, por un lado, bases de datos transaccionales de envíos de clientes (estructurados) y, por otro, ficheros provenientes de fuentes externas abiertas de tráfico, meteorología y precios de carburantes, además de flujos continuos de datos de sensores.

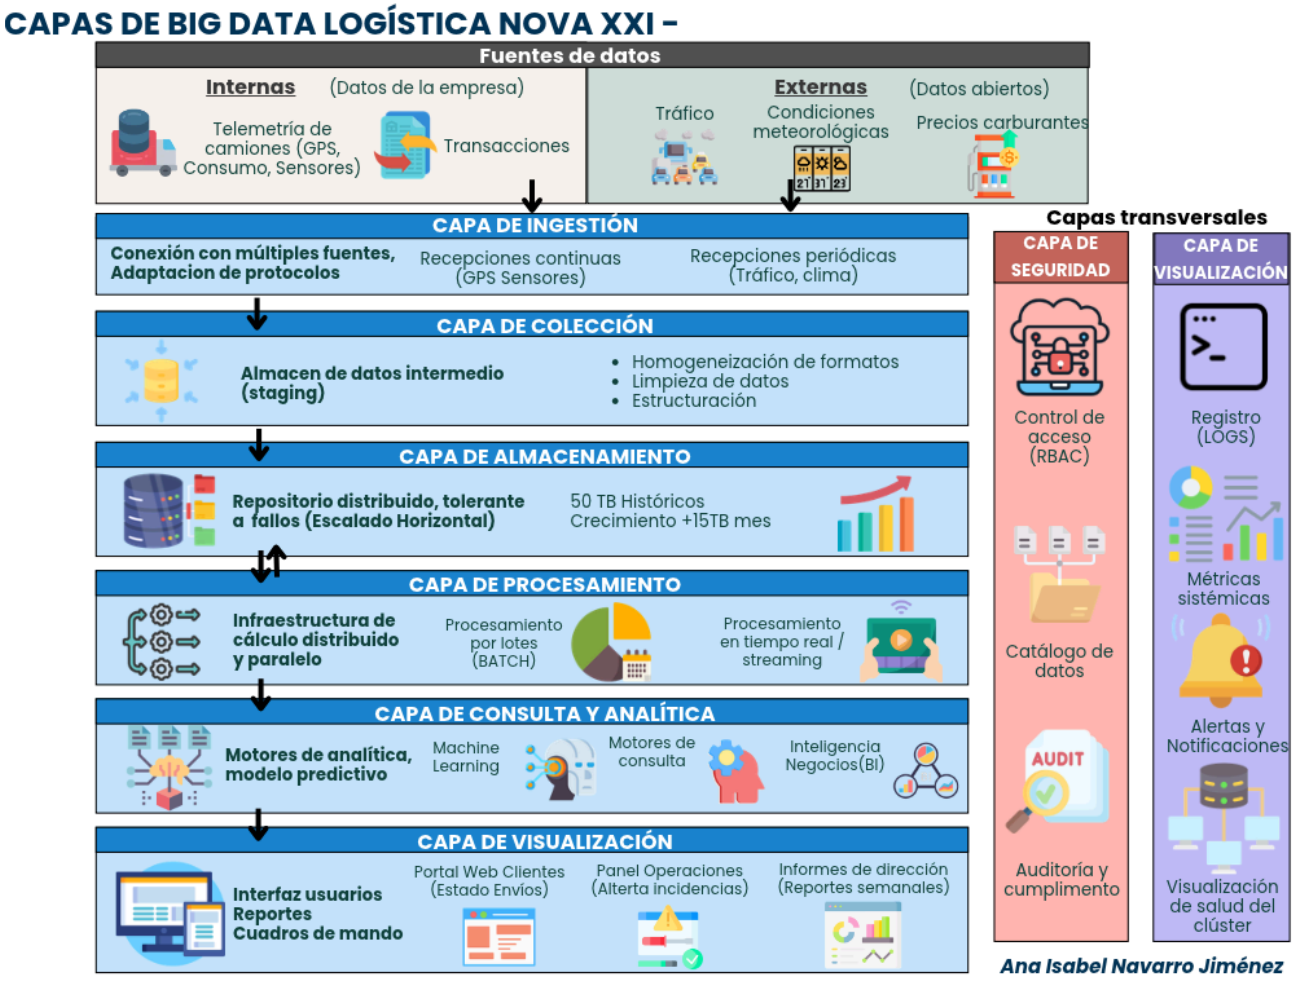
4. Veracidad: Comprende el grado de fiabilidad, calidad y exactitud de los datos recopilados, vinculándose directamente con la relación señal-ruido. Los datos externos o los sensores de los camiones pueden presentar imprecisiones, intermitencias o ruido informacional. Por consiguiente, resulta indispensable implementar mecanismos de depuración y validación para garantizar que la toma de decisiones no se base en información errónea.

5. Valor: Define la utilidad estratégica que se extrae de la explotación y análisis de los datos. Para Logística Nova XXI, el valor se materializa en la capacidad de ofrecer a los clientes consultas en línea sobre el estado de sus envíos, optimizar el rendimiento de la flota mediante la prevención de averías, reducir costes de combustible y anticipar retrasos en las rutas a través de modelos predictivos.

2. Propuesta de arquitectura Big Data:

Incluye un diagrama sencillo y una explicación escrita. El estudiante debe describir cómo se organizarían las capas mínimas del sistema: ingesta de datos, almacenamiento, procesamiento, analítica y gobierno. Debe explicar por qué se necesita cada capa y cómo se relacionan entre sí, mencionando tecnologías tipo (no marcas obligatorias). El objetivo es que quede claro cómo se construiría la solución de manera lógica.

El diagrama elabora es el siguiente:



(*) Elaboración propia en la aplicación Canva - Iconos de la web: *https://www.flaticon.es/*

Como punto de partida, las **fuentes de datos** de la empresa se pueden agrupar en dos grandes categorías:

- **Fuentes externas:** Datos heterogéneos de carácter abierto, tales como información de tráfico, condiciones meteorológicas y precios de carburantes.
- **Fuentes internas:** Datos generados por la propia actividad de la compañía, destacando la telemetría en tiempo real de la flota de camiones (posicionamiento GPS, consumo de combustible y sensores de mantenimiento) y las transacciones de envíos de los clientes.

A partir de estas fuentes de origen, el flujo de información se organiza secuencialmente a través de las siguientes capas del sistema Big Data:

1. **Capa de Ingestión:** Actúa como el punto de entrada encargado de conectar el sistema con las múltiples fuentes de datos, adaptándose a sus respectivos protocolos de comunicación sin alterar los sistemas de origen. En la empresa, agrupa los módulos de captura adaptados para recibir de forma periódica las actualizaciones de tráfico y clima, así como de forma continua los datos procedentes de los dispositivos

GPS y sensores de los camiones en carretera. Usaría tecnologías tipo como pasarelas API y sistemas de mensajería o brokers de ingesta continua y por lotes. Recoge los datos en bruto de los orígenes externos e internos y los canaliza directamente hacia la siguiente capa.

2. **Capa de Colección:** Integra y unifica los datos heterogéneos procedentes de la ingestión para dotarlos de una estructura coherente y con sentido propio. En la compañía, se implementa mediante un área de almacenamiento intermedio (staging) donde se unifican y limpian los registros de envíos de los clientes junto con los datos meteorológicos y de geolocalización, homogeneizando los diferentes formatos de entrada. Utilizaría áreas de almacenamiento intermedio (staging areas) y flujos de normalización ETL. Por lo tanto en esta capa se reciben los flujos heterogéneos del nivel de ingesta, se elimina el ruido y se unifican los esquemas antes de pasarlos al repositorio definitivo.

3. **Capa de Almacenamiento:** Repositorio distribuido y tolerante a fallos diseñado específicamente para soportar los grandes volúmenes de datos propios del Big Data. Para Logística Nova XXI, representa el repositorio masivo capaz de absorber de forma segura los 50 TB de datos históricos y el crecimiento estimado de +15 TB mensuales generados por los nuevos sensores de la flota y el histórico de transacciones. Utilizaría sistemas de ficheros distribuidos (tipo Hadoop/S3), bases de datos NoSQL y repositorios corporativos tipo Data Warehouse. Por lo que se relaciona almacenando de manera persistente y distribuida los datos limpios, sirviendo como base de lectura masiva para alimentar los motores de procesamiento y analítica.

4. **Capa de Procesamiento**: Proporciona la infraestructura de cálculo distribuido y paralelo necesaria para tratar los datos mediante diferentes estrategias operativas. Utiliza frameworks de procesamiento distribuido en paralelo para cargas masivas y motores de computación en tiempo real. Desglose de estrategias en la empresa:

    - Por lotes (Batch): Procesamiento diferido destinado a calcular el informe semanal de dirección con datos cerrados el domingo (analizando costes de combustible, puntualidad y utilización de la flota).
    - Tiempo real / Streaming: Procesamiento inmediato de la telemetría de los camiones para detectar incidencias y emitir alertas automáticas ante averías o desvíos de ruta.

    Extrae la información desde el almacenamiento (o la intercepta al vuelo en streaming) para ejecutar los cálculos lógicos requeridos, proveyendo la infraestructura base para la capa superior de analítica.

5. **Capa de Consulta y Analítica:** Subsistema equipado con motores de analítica donde se extrae valor real de los datos mediante estadística, algoritmia y minería de datos. En Logística Nova XXI, engloba el entorno analítico encargado de ejecutar el modelo predictivo para anticipar retrasos probables en las rutas, basándose en el cruce de datos históricos de tráfico, clima e incidencias. Utilizaría tecnológicas como librerías de aprendizaje automático (Machine Learning), motores de consulta SQL interactivos y subsistemas OLAP (Online Analytical Processing) para Business intelligence. En esta capa se toma los datos procesados por la capa inferior para transformarlos en conocimiento predictivo e inteligencia de negocio, suministrando los resultados analíticos listos para su visualización.

6. **Capa de Visualización**: Interfaz final con la que interactúa el usuario mediante reportes o cuadros de mando interactivos orientados a la toma de decisiones. Para nuestro caso práctico, incluye el portal web habilitado para que los clientes consulten en línea el estado diario de sus envíos, así como los paneles de control específicos para el departamento de operaciones (alertas de incidencias) y para la dirección general (informes descriptivos semanales). Utiliza tecnologías como cuadros de mando interactivos (dashboards), portales web de usuario y herramientas de gestión. Consume la información generada en la capa de analítica y la presenta de forma gráfica y accesible para los diferentes perfiles de usuario de la compañía.

7. **Capas Transversales (Seguridad y Monitorización**): Capas de soporte global que garantizan la protección física y lógica de los datos (seguridad) y la gobernanza, auditoría y control de calidad (monitorización). En Logística Nova XXI, comprende la implementación de mecanismos destinados a garantizar la privacidad y el control de acceso a los datos confidenciales de los clientes, combinados con la supervisión continua de la salud y el rendimiento del clúster de servidores de la empresa. Utiliza sistemas de control de acceso basado en roles (RBAC), protocolos de autenticación (IAM), cifrado de datos en reposo y en tránsito, y herramientas de auditoría de linaje y calidad de datos.

3. Justificación de decisiones clave:

Explica qué estrategia de escalado usarías para el clúster (horizontal o vertical), en qué partes es importante mantener las propiedades ACID y en cuáles es más adecuado BASE, cuándo se requieren subsistemas OLTP y OLAP, y si sería conveniente incorporar un Data Warehouse. Aquí no basta con responder sí/no, sino que se espera una breve argumentación.

Para garantizar que la infraestructura de Logística Nova XXI sea escalable, segura y eficiente, es necesario justificar técnicamente las decisiones de diseño adoptadas respecto al escalado, los modelos de consistencia, los subsistemas transaccionales y analíticos, y el almacenamiento centralizado:

Estrategia de escalado del clúster

Se seleccionará un escalado horizontal (scale-out) en lugar de uno vertical. En entornos Big Data, donde el volumen de datos históricos (50 TB) y el crecimiento mensual (+15 TB) superan con creces las especificaciones físicas de cualquier máquina individual, añadir nodos económicos al clúster permite crecer de forma indefinida y evitar los cuellos de botella propios de la ampliación vertical (scale-in) de un único servidor.

Propiedades ACID frente a BASE

- **ACID** (Atomicidad, Consistencia, Aislamiento y Durabilidad): Se aplicará estrictamente en los subsistemas encargados de las transacciones de envíos de los clientes y las consultas en línea, donde la consistencia absoluta de los datos comerciales y monetarios es un requisito crítico e innegociable.
- **BASE** (Básicamente disponible, Estado blando y Consistencia eventual): Se adoptará en el almacenamiento distribuido masivo destinado a la recepción continua de telemetría de los camiones y datos de sensores. En este escenario, priorizamos la alta disponibilidad y la tolerancia al particionamiento del sistema (evitando que el clúster se detenga ante fallos de red), permitiendo que los datos converjan de manera eventual.

Subsistemas OLTP y OLAP

Se requiere un subsistema OLTP (Procesamiento Analítico y Transaccional en Línea) para gestionar la operativa diaria y permitir que los clientes consulten el estado actual de sus envíos con tiempos de respuesta inferiores a un segundo.

Se requiere un subsistema OLAP (Procesamiento Analítico en Línea) para que la dirección general y los analistas ejecuten consultas complejas sobre cubos de datos multidimensionales y desnormalizados, facilitando la toma de decisiones informadas.

Incorporación de un Data Warehouse

Es completamente conveniente incorporar un Data Warehouse corporativo. Este repositorio centralizado se alimentará periódicamente mediante procesos ETL desde las fuentes internas y externas (ERP, CRM y bases de datos transaccionales), consolidando una instantánea histórica limpia para la generación de los informes semanales de dirección.

4. Estrategias de procesamiento:

Para cada necesidad de negocio, indica si resolverías el problema con procesamiento batch, en tiempo real o streaming, y explica por qué. El estudiante debe relacionar el tipo de procesamiento con el caso de uso concreto (alertas, informes, predicción, etc.).

Para dar cumplimiento a los requisitos operativos y analíticos de Logística Nova XXI, se seleccionará una estrategia de procesamiento específica para cada caso de uso en función de la urgencia de la respuesta y el volumen de datos:

Consulta en línea del estado de los envíos (transacciones diarias)

Utilizaría un procesamiento transaccional (en tiempo real / online). Ya que los clientes necesitan consultar el estado actual de sus envíos de forma inmediata, exigiendo tiempos de respuesta inferiores a un segundo. Se apoya en subsistemas OLTP sobre bases de datos operacionales para resolver operaciones de lectura y actualización rápidas.

Alertas en tiempo real para incidencias (retrasos, averías, desvíos de ruta)

Usaría un procesamiento en streaming. Ya que los sensores de la flota y el posicionamiento GPS generan un flujo continuo y constante de datos en movimiento. El sistema debe procesar estos flujos al vuelo, de forma ininterrumpida, para detectar anomalías de manera instantánea y emitir alertas operativas sin demoras.

Informe semanal con métricas descriptivas (costes de combustible, puntualidad, utilización de la flota) con datos cerrados el domingo

Utilizaría procesamiento por lotes (batch / offline). Ya que, dados que los datos se cierran al finalizar la semana (el domingo) y no se requiere una respuesta inmediata o en milisegundos, se programa un proceso pesado que analiza de forma diferida el gran volumen de datos históricos acumulados para calcular las métricas descriptivas globales.

Modelo predictivo que anticipe retrasos probables en rutas según datos históricos

Utilizaría un procesamiento por lotes (batch) combinado con analítica avanzada. Debido a que el entrenamiento del modelo predictivo requiere procesar masivos volúmenes de datos históricos (patrones de tráfico y clima pasados), una tarea computacionalmente pesada que se ejecuta periódicamente en segundo plano sin restricciones estrictas de tiempo de respuesta inmediato.

5. Equilibrio CAP y SCV:

Explica con tus palabras cómo se aplicarían los principios de CAP y SCV al diseño elegido. Por ejemplo, dónde priorizas disponibilidad frente a consistencia, o dónde prefieres rapidez aunque se pierda consistencia temporal.

Para aplicar los principios de CAP y SCV en Logística Nova XXI, adaptamos las reglas del sistema a lo que realmente necesita cada parte de la empresa.

En cuanto al almacenamiento de los datos y el teorema CAP, como lo más importante es que el sistema nunca se quede tirado ante un corte de red, elegimos dar prioridad total a que los equipos sigan funcionando (tolerancia a particiones). A partir de ahí, para la zona donde los clientes consultan el estado de sus envíos y hacen transacciones exigimos una seguridad y exactitud total (consistencia), aunque eso signifique bloquear la pantalla un segundo si hay fallos de red; en cambio, para guardar todos los datos que envían los sensores y GPS de los camiones de forma masiva, preferimos que el sistema jamás se interrumpa y nos dé los datos a la velocidad posible, aceptando que se actualicen por completo un instante después (disponibilidad y consistencia eventual mediante la filosofía BASE).

Por otra parte, al hablar del procesamiento de esos datos y del principio SCV, como manejamos un volumen gigantesco de información, tenemos que elegir entre velocidad o precisión según el caso: para las alertas urgentes de averías o desvíos del departamento de operaciones necesitamos una velocidad extrema, lo que nos obliga a analizar muestras rápidas sin esperar a revisar todo el histórico para avisar al momento; en cambio, para los informes semanales que la dirección revisa tranquilamente los lunes, como no hay prisa, prescindimos de la velocidad y nos tomamos el tiempo necesario para procesar el 100% de los datos con absoluta precisión y exactitud.

6. Modelo predictivo:

Propón de manera sencilla un modelo para anticipar retrasos en rutas. Indica qué datos usarías como variables de entrada, qué quieres predecir exactamente y cómo lo entrenarías (ej. con históricos). No hace falta código, solo una idea razonada.

Para anticipar los retrasos probables en las rutas y dar soporte al área de planificación, se propone un modelo predictivo basado en técnicas de aprendizaje automático (Machine Learning) que funcionará con el objetivo de anticipar la probabilidad de que un camión sufra un retraso significativo en su ruta programada, o estimar el tiempo exacto de retraso (en minutos) antes de iniciar el trayecto o mientras este se encuentra en curso.

Variables de entrada (Datos): Para que el modelo pueda aprender y realizar inferencias acertadas, se utilizarán como datos de entrada una combinación de información histórica y de contexto actual, tales como:

Variables de contexto temporal y operativo:

- Franja horaria y día de la semana: El momento en el que se inicia o transcurre el trayecto (horas punta de entrada a grandes ciudades, días laborables frente a fines de semana o periodos festivos), lo que impacta directamente en los patrones de tráfico.
- Planificación del itinerario: Número de paradas intermedias programadas, tipo de ruta (urbana, interurbana o de media/larga distancia) y el nivel de holgura o margen de tiempo asignado inicialmente al transportista.

Variables asociadas a la carga y al tipo de mercancía:

- Nivel de ocupación y peso de la carga: El porcentaje de capacidad utilizado en el camión y el peso transportado, ya que influyen en el comportamiento dinámico del vehículo en pendientes, en el consumo de combustible y en su velocidad media de circulación.
- Naturaleza del envío: Si la mercancía requiere condiciones especiales (como control de temperatura para productos perecederos) o si se trata de envíos urgentes, lo que puede condicionar paradas técnicas o exigencias operativas.

Variables de factor humano y rendimiento del conductor:

- Historial de cumplimiento del conductor: Métricas agregadas de puntualidad previa del chofer asignado a la ruta y su nivel de experiencia en tramos geográficos complejos.
- Tiempos de descanso y normativa: Estado de las horas de conducción acumuladas según los tacógrafos inteligentes para prever paradas obligatorias de descanso que puedan afectar al tiempo total de entrega.

Cómo se entrenaría: El entrenamiento se realizaría utilizando el enorme volumen de datos históricos acumulados en el clúster de almacenamiento de la compañía. Mediante un algoritmo supervisado de aprendizaje automático (como árboles de decisión o modelos de regresión), el sistema analizaría miles de trayectos pasados para encontrar patrones ocultos y correlaciones por ejemplo, cómo influye una fuerte lluvia combinada con un determinado nivel de tráfico en el retraso final de un envío. Una vez entrenado con el pasado, el modelo se aplicará de forma periódica o automatizada para predecir el comportamiento de las nuevas rutas planificadas.